

武汉大学学报(信息科学版)

Geomatics and Information Science of Wuhan University

ISSN 1671-8860, CN 42-1676/TN

## 《武汉大学学报(信息科学版)》网络首发论文

题目: 时空序列嵌入门控扩张残差网络的兴趣点推荐  
作者: 姜涛, 徐胜华, 李晓燕, 张志然, 王勇, 罗安, 何璇  
DOI: 10.13203/j.whugis20220658  
收稿日期: 2023-06-04  
网络首发日期: 2023-07-04  
引用格式: 姜涛, 徐胜华, 李晓燕, 张志然, 王勇, 罗安, 何璇. 时空序列嵌入门控扩张残差网络的兴趣点推荐[J/OL]. 武汉大学学报(信息科学版).  
<https://doi.org/10.13203/j.whugis20220658>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

DOI:10.13203/j.whugis20220658

引用格式：

姜涛，徐胜华，李晓燕，等. 时空序列嵌入门控扩张残差网络的兴趣点推荐[J]. 武汉大学学报（信息科学版），2023，DOI: 10.13203/j.whugis20220658（JIANG Tao, XU Shenghua, LI Xiaoyan, et al. POI Recommendation of Spatiotemporal Sequence Embedding in Gated Dilation Residual Network [J]. *Geomatics and Information Science of Wuhan University*, 2023, DOI: 10.13203/j. whugis20220658）

# 时空序列嵌入门控扩张残差网络的兴趣点推荐

姜涛<sup>1,2</sup>，徐胜华<sup>2</sup>，李晓燕<sup>3</sup>，张志然<sup>4</sup>，王勇<sup>2</sup>，罗安<sup>2</sup>，何璇<sup>3</sup>

1. 武汉大学资源与环境科学学院，武汉，430000
2. 中国测绘科学研究院地理空间大数据应用研究中心，北京，100830
3. 辽宁工程技术大学测绘与地理科学学院，辽宁，123000
4. 西安石油大学地球科学与工程学院，陕西，710065

**摘要：**个性化兴趣点推荐是基于位置社交网络的一项重要服务，通过挖掘用户签到数据的序列信息和时空上下文信息可以有效挖掘用户的移动模式和兴趣偏好。本文为充分挖掘用户的个性化时空偏好和连续签到序列的长期依赖关系，提出嵌入时空条件的概率生成模型，构建门控扩张残差网络，实现基于门控扩张残差网络的兴趣点推荐方法（OurNet）。本文方法通过门控扩张残差网络学习用户的签到序列，将用户连续签到的空间距离和时间间隔作为约束条件，挖掘用户连续签到行为的时空规律，捕获用户签到行为的序列偏好和时空偏好。本文方法在 Foursquare 和 Instagram 数据集上得到显著的改进效果。与表现最好的对比算法 NextItNet 相比，我们的方法在召回率、精确度、F1 分数和归一化折损累计增益等评价指标上都有明显提升。在 Foursquare 数据集上，提升范围为 1.52% 到 24.95%；在 Instagram 数据集上，提升范围为 7.06% 到 42.47%。本文提出方法更加适用于挖掘用户连续签到中存在的长期依赖关系，可以有效嵌入空间距离和时间间隔影响因素，提高了 POI 推荐的准确性。

**关键词：**兴趣点推荐；空间距离；时间间隔；生成模型；门控扩张残差

中图法分类号：P208

文献标识码：A

## POI Recommendation of Spatiotemporal Sequence Embedding in Gated Dilation Residual Network

JIANG Tao<sup>1,2</sup>, XU Shenghua<sup>2\*</sup>, LI Xiaoyan<sup>3</sup>, ZHANG Zhiran<sup>4</sup>, WANG Yong<sup>2</sup>, LUO An<sup>2</sup>, HE Xuan<sup>3</sup>

1 School of Resource and Environmental Sciences, Wuhan University, Hubei Wuhan, 430000

2 Geospatial Big Data Application Research Center, Chinese Academy of Surveying and Mapping, Beijing Beijing, 100830

收稿日期：2023-06-04

项目资助：国家自然科学基金（42071384）

第一作者：姜涛，博士生，主要研究方向为兴趣点推荐。E-mail: jiangta0@whu.edu.cn

通讯作者：徐胜华，博士，研究员。E-mail: xushh@casm.ac.cn

**Abstract: Objectives:** Personalized point-of-interest (POI) recommendation is a vital service in location-based social networks (LBSNs). It can effectively use the sequence and spatiotemporal context information of check-in data to discover users' movement patterns and preferences. **Methods:** This paper proposes a probabilistic generative model with embedded spatiotemporal conditions to fully exploit the long-term dependency between users' personalized spatiotemporal preferences and sequential check-in sequences, constructs a gated dilation residual network, and implements a POI recommendation method based on gated dilation residual network. The method in this paper learns users' check-in sequences through a gated dilation residual network. It mines and captures the spatiotemporal patterns, sequence preferences and temporal preferences of users' sequential check-in behaviour using the spatial distance and time interval of users' sequential check-ins as constraints. **Results:** The proposed method in this paper shows significant improvements on the Foursquare and Instagram datasets. Compared to the best-performing algorithm NextItNet, our method demonstrates noticeable enhancements in terms of recall, precision, F1 score, and normalized discounted cumulative gain (NDCG). On the Foursquare dataset, we achieve improvements ranging from 1.52% to 24.95%. On the Instagram dataset, the improvements range from 7.06% to 42.47%. **Conclusions:** The proposed method is more suitable for mining the long-term dependency relationships in continuous user check-ins. It effectively incorporates spatial distance and temporal interval factors, thereby improving the accuracy of POI recommendation. **Keywords:** POI recommendation; spatial distance; time interval; generative model; gated dilation residual

随着移动互联网和智能移动设备的普及,人们越来越倾向于在基于位置的社交网络(Location-based Social Networks, LBSNs)中分享个人的日常生活。LBSNs中积累了大量的用户签到数据,对研究用户的活动和行为提供了重要数据支撑。个性化兴趣点(Point-of-Interest, POI)推荐在LBSNs中发挥着重要作用,既可满足用户访问新地点的个性化偏好,以提供智能化位置服务,又可为位置服务提供商提高经济效益<sup>[1,2]</sup>。个性化POI推荐有助于用户签到新的有吸引力的地点,可融入用户个性化时空上下文特征,充分挖掘用户日常行为轨迹,对用户的移动行为预测具有重要的研究价值。

个性化POI推荐在LBSNs领域已得到广泛研究,与新闻、视频、商品推荐不同,POI推荐侧重考虑地理影响、时间影响、序列影响等。早期的POI推荐方法主要有基于贝叶斯网络成对排序方法<sup>[3,4]</sup>、基于协同过滤方法<sup>[5-8]</sup>和基于矩阵分解方法<sup>[9-12]</sup>。许多兴趣点推荐研究使用了贝叶斯网络成对排序方法,如Rendle等<sup>[3]</sup>提出一种基于用户的隐式反馈和贝叶斯网络特性的经典成对排序兴趣点推荐算法。Feng等<sup>[4]</sup>整合序列信息、个性化偏好和地理影响提出一种度量嵌入式成对排序方法,对用户个性化签到序

列进行建模。基于协同过滤的POI推荐方法,宋亚伟等人<sup>[5]</sup>融合了时间特征和协同过滤算法对兴趣点进行推荐,从用户的签到数据中提取用户签到的相似性,并以此对用户进行过滤,然后再结合时间上的差异性对用户进行推荐。包玄等<sup>[6]</sup>利用时间关系对用户签到数据进行平滑处理,然后基于用户的协同过滤算法,提出了融入时间的协同过滤POI推荐算法。任星怡等<sup>[7]</sup>有效地整合POI的地理信息、用户社交关系、用户偏好类别和POI流行度等影响因素,提出一种基于上下文感知的概率矩阵分解的POI推荐方法。张国明等<sup>[8]</sup>提出一种基于霍克斯过程的上下文感知协同过滤POI推荐算法。基于矩阵分解的POI推荐方法,何颖等人<sup>[9]</sup>提出一种融合社交地理位置信息的加权矩阵分解POI推荐算法,将社交地理信息进行建模挖掘出用户对未访问位置的偏好并以隐反馈项的形式改进加权矩阵分解的目标函数。Gao等<sup>[10]</sup>在矩阵分解模型的基础上,融合用户显式和隐式的社会信任关系,对稀疏的用户-POI矩阵进行数据填充。Cheng等<sup>[11]</sup>考虑用户活动的区域约束和个性化马尔可夫链,提出新的矩阵分解方法,降低了计算成本并提高了推荐准确率。Cai等<sup>[12]</sup>结合加权最小二乘法和成对排序函数,融入时间和空

间上下文信息，提出一种特征空间分解模型。传统的矩阵分解和协同过滤方法，易导致存在冷启动问题，对挖掘用户长期依赖关系具有挑战性。

近年来，深度学习被广泛应用于各领域<sup>[13-15]</sup>，这为提高 POI 推荐性能带来了新的解决途径<sup>[16-18]</sup>。POI 推荐中广泛应用的神经网络有卷积神经网络（Convolutional Neural Networks, CNN）、循环神经网络（Recurrent Neural Network, RNN）。其中，RNN 可以建模用户短期签到行为，但存在梯度消失和爆炸的问题。因此，Cho 等<sup>[19]</sup>和 Liu<sup>[20]</sup>等为更好地捕捉用户签到行为的长期依赖关系使用门控循环单元（Gated Recurrent Unit, GRU）。为了更好地解决用户连续签到序列的长期依赖关系问题，一些学者<sup>[21-23]</sup>引入在语音序列处理领域知名的网络结构 WaveNet<sup>[24]</sup>。如 Yuan 等<sup>[21]</sup>引入简单有效的概率生成模型，该模型的网络结构由扩张卷积和残差网络构成，简化了深层次网络结构，优化了模型的训练时间和精度，但没有考虑用户连续签到的时间间隔和空间距离变化的影响。

从现有的研究成果来看<sup>[19-21,25]</sup>，如何挖掘用户签到序列的长期依赖关系具有一定的挑战性，基于马尔可夫链的方法存在较强的独立性假设，难以挖掘用户签到序列中存在的长期依赖关系，并且传统的浅层方法难以深度融合时空上下文信息和有效地学习用户签到序列中隐含的深层交互关系。针对上述问题，本文提出嵌入时空条件的概率生成模型，构建门控扩张残差网络，实现基于门控扩张残差网络的兴趣点推荐方法（OurNet），提升个性化 POI 推荐的准确度。

## 1 嵌入时空序列的 POI 推荐

### 1.1 问题描述

已知用户集合  $U = \{u_1, u_2, \dots, u_n\}$ ， $n$  为用户个数；用户连续 POI 位置序列，即用户在相同或不同位置的连续签到行为构成的序列，可表示为  $L^U = (L_1^U, L_2^U, \dots, L_{|L^U|}^U)$ ；用户连续签到时间序列，即用户在相同或不同签到位置连续签到时的时间构成的序列，可表示为  $T^U = (T_1^U, T_2^U, \dots, T_{|T^U|}^U)$ ；位置  $L_i^U$  的坐标为  $(x_i^U, y_i^U)$ 。给定用户  $U$  位置  $L_i^U(x_i^U, y_i^U)$  与位置  $L_j^U(x_j^U, y_j^U)$ ，对应签到位置的时间戳分别为  $T_i^U$  和  $T_j^U$ ，则连续签到时间间隔为  $r_{i,j}^U = |T_j^U - T_i^U|$ ，用户连续签到位置的球面距离（下文均表示为空间距离）为

$$d_{i,j}^U = r \cdot \arccos(\sin(x_i^U) \cdot \sin(x_j^U) + \cos(x_i^U) \cdot \cos(x_j^U) \cdot \cos(y_i^U - y_j^U))$$

其中， $i < j$ ， $r$  为地球半径。计算全部用户连续签到

时间间隔和空间距离，构建时间间隔序列  $R^U$  和空间距离序列  $D^U$ 。在本文模型训练期间，输入为位置序列  $(L_1^U, L_2^U, \dots, L_{|L^U|-1}^U)$ 、时间间隔序列  $R^U$  和空间距离序列  $D^U$ ，输出为  $(L_2^U, \dots, L_{|L^U|}^U)$ 。本文主要基于用户在 LBSN 中大量的历史签到数据，分析用户的签到行为规律，给出合理的预测模型，估计用户历史连续签到序列上的概率分布，为用户推荐 POI。

### 1.2 嵌入条件序列

已知数据集中位置序列为  $(L_1^U, L_2^U, \dots, L_{|L^U|-1}^U)$ ，将其转化为固定长度位置序列  $L^U = (L_1^U, L_2^U, \dots, L_N^U)$ ，其中  $N$  表示设置的最大序列长度，如果序列长度小于  $N$ ，则在序列左侧填充“-1”至长度为  $N$ 。如果序列长度大于  $N$ ，则仅考虑最近  $N$  的签到记录，剩余项作为新签到序列进行补全或截取。同理，得到固定长度的时间序列  $T^U = (T_1^U, T_2^U, \dots, T_N^U)$ 。用户连续签到的空间距离和时间间隔对用户签到行为存在影响，本文将空间距离和时间间隔作为嵌入条件，计算每个用户  $u$  连续签到的时间间隔和空间距离，分别得到时间间隔序列矩阵  $R^U$  和空间距离序列矩阵  $D^U$ 。 $L^U$ ， $R^U$ ， $D^U$  表示如公式（1）。

$$\begin{aligned} L^U &= \begin{bmatrix} L_1^{u_1} & L_2^{u_1} & \dots & L_N^{u_1} \\ L_1^{u_2} & L_2^{u_2} & \dots & L_N^{u_2} \\ \dots & \dots & \dots & \dots \\ L_1^{u_n} & L_2^{u_n} & \dots & L_N^{u_n} \end{bmatrix} \\ R^U &= \begin{bmatrix} R_1^{u_1} & R_2^{u_1} & \dots & R_{N-1}^{u_1} \\ R_1^{u_2} & R_2^{u_2} & \dots & R_{N-1}^{u_2} \\ \dots & \dots & \dots & \dots \\ R_1^{u_n} & R_2^{u_n} & \dots & R_{N-1}^{u_n} \end{bmatrix} \\ D^U &= \begin{bmatrix} D_1^{u_1} & D_2^{u_1} & \dots & D_{N-1}^{u_1} \\ D_1^{u_2} & D_2^{u_2} & \dots & D_{N-1}^{u_2} \\ \dots & \dots & \dots & \dots \\ D_1^{u_n} & D_2^{u_n} & \dots & D_{N-1}^{u_n} \end{bmatrix} \end{aligned} \quad (1)$$

### 1.3 时空条件概率生成模型

概率生成模型易扩展，能建模复杂系统并更快地收敛于真实模型，能充分挖掘特征之间复杂的潜在结构关系并有效融合多维特征。时空条件概率生成模型是一种用于推荐系统的有效方法，它使用非常精细和复杂的模型来评估目标用户，以及考虑到时间或位置信息的关系。时空条件概率生成模型可以预测用户对特定 POI 的感兴趣度，并个性化推荐相关 POI，以提升推荐的准确性和有效性。

本文考虑用户连续签到的空间距离和时间间隔作为补充限制条件，提出时空条件概率生成模型，



根据条件概率链式法则把它分解成条件分布的乘积形式，如公式（2）所示。

$$p(L|R, D, \theta) = \prod_{t=1}^{N-1} p(L_{t+1} | L_1, \dots, L_t, R_1, \dots, R_t, D_1, \dots, D_t, \theta) \quad (2)$$

其中， $p(L|R, D, \theta)$  为用户在连续签到前  $t$  的位置序列、时间间隔序列和空间距离序列的条件下，签到  $t+1$  个位置的概率； $\theta$  为模型求解参数  $(W, B)$ ，即权重与偏置。

## 2 基于门控扩张残差的 POI 推荐网络

### 2.1 一维扩张卷积

假设嵌入维度为  $2c$ ，样本数量为  $t$ ，得到一个  $t \times 2c$  的输入矩阵。与标准卷积过程中将输入矩阵视为二维“image”不同，本文通过一维扩张卷积滤波器学习嵌入层。为了对二维输入进行建模，本文执行一个简单的重塑操作，用以实现一维扩张卷积。该操作将二维输入矩阵从  $t \times 2c$  重塑到  $1 \times t \times 2c$  的一个三维张量，其中  $2c$  视为“image”通道，图 1 显示了重塑过程。

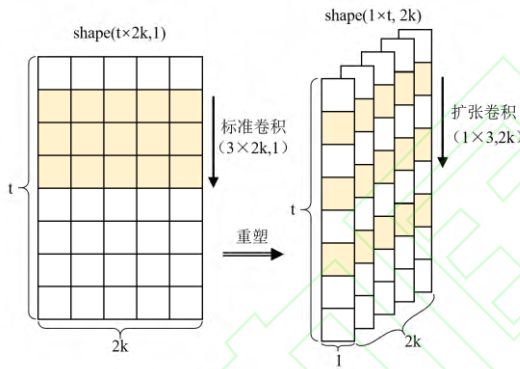


图 1 标准卷积（通道为 1）重塑为一维扩张卷积（通道为  $2c$ ）

Fig.1 The standard convolution (channel is 1) is reshaped into a 1D dilated convolution (channel is  $2c$ )

### 2.2 门控扩张残差网络

在神经网络中增加网络深度可以更好地挖掘出数据特征，但易导致学习梯度的消失和网络退化问题<sup>[21,22,26,27]</sup>。为缓解此类问题，本文引入残差网络<sup>[28]</sup>，其基本思想是将多个卷积层堆叠在一起作为一个块，采用跳跃连接方法，将前一层的输入特征矩阵传递到后一层。跳跃连接允许显式拟合残差映射而不是原始身份映射，进而维护输入特征矩阵并扩大传播的梯度。根据文献<sup>[21]</sup>可知，扩张卷积可以更好地捕获用户长期签到序列，可避免更深层网络和更大的卷积核。扩张残差网络在兴趣点推荐上的优势有：可以有效地学习和抽取用户行为特征，通过对高维数据进行抽象，提高网络预测的准确性；可以有效地处理大规模稀疏数据，并准确预测用户的喜好。

因此，本文构建门控扩张残差网络，如图 2 所示。该网络结构包括一维扩张卷积、层归一化、激活函数  $\text{relu}$  和一个门控结构（由  $\tanh$  函数和  $\sigma$  函数组成）。其中，一维扩张卷积可实现对嵌入矩阵降维，加快网络迭代速度，可聚合多尺度上下文信息，提高深度神经网络预测的准确性。层归一化可对神经元的输入进行规范化处理而加快网络收敛速度，门控结构用于控制在层次结构中传递的信息，减轻梯度传播。为进一步增加感受野和网络容量，避免序列信息丢失，需要设置多个不同的扩张因子来重复门控扩张残差网络。

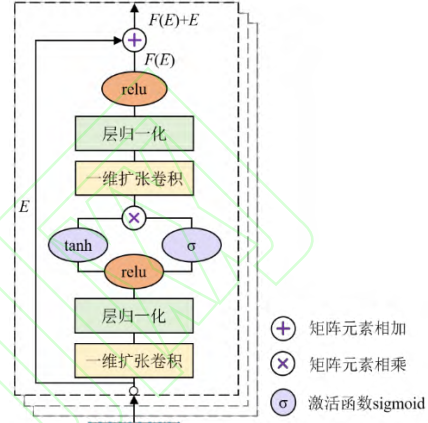


图 2 门控扩张残差网络  
Fig.2 Gated dilation residual network

根据图 2 门控扩张残差网络可以得到残差映射  $F(E)$ 。先利用一维扩张卷积对矩阵  $E$  进行降维，并对其做层归一化处理来加快网络收敛速度，采用  $\text{relu}$  函数作为激活函数，如公式（3）所示；再经过门控（由  $\tanh$  函数和  $\sigma$  函数组成）来减轻梯度传播，如公式（4）所示；最后将其进行一维扩张卷积、层归一化处理，采用  $\text{relu}$  函数作为激活函数，如公式（5）所示：

$$f_1(E) = \text{relu}(\psi_1(w_1 E + b_1)) \quad (3)$$

$$f_2(E) = \tanh(f_1(E)) \otimes \sigma(f_1(E)) \quad (4)$$

$$F(E) = \text{relu}(\psi_2(w_2(f_2(E)) + b_2)) \quad (5)$$

其中， $\psi_1$  和  $\psi_2$  表示层归一化， $w_1$  和  $w_2$  一维扩张卷积的权重， $b_1$  和  $b_2$  为一维扩张卷积的偏置项， $\otimes$  表示矩阵之间元素相乘。

### 2.3 基于门控扩张残差的 POI 推荐网络

本文为实现上述 1.3 节中提出的时空条件概率生成模型，设计如图 3 网络结构。该网络结构包括三个并行网络通道，分别为位置序列通道、空间距离序列通道和时间间隔序列通道。每个通道将相应的嵌入序列通过 Lookup 表检索前  $t$  项，并分别使用一维扩张卷积进行预处理，对嵌入数据进行降维，

提取更深层数据特征。在时空条件概率生成模型下，空间距离序列与时间间隔序列为限制性条件，在本文设计网络中两个限制条件分别单独经过各自网络通道处理，输入门控扩张残差结构中，学习各隐藏层中的隐藏特征，将每个通道学习的隐藏特征进行相加处理，预测出限制条件下用户连续签到位置为变化的隐藏特征。




图3 基于门控扩张残差的 POI 推荐网络

Fig.3 POI recommendation network based on gated dilation residual

最后，该网络使用激活函数  $\text{relu}$  来整合具有类别区分性的局部信息，经二维卷积学习得到输出序列  $\text{logits}$ ， $\text{logits}$  与输入位置序列维度相同，为得到输出序列中所有元素的概率分布，使用激活函数  $\text{softmax}$  将  $\text{logits}$  转化为加和为 1 的概率序列，如公式 (6) 所示。

$$p_i = \text{softmax}(\text{logits}_i) = \left[ \frac{e^{\text{logits}_i}}{\sum_{j=0}^{\text{numclasses}-1} e^{\text{logits}_j}} \right] \quad (6)$$

其中， $p$  为概率， $i$  为输出序列行数， $\text{numclasses}$  为类别个数。

上述提出的 POI 推荐方法嵌入用户连续签到位置序列、空间距离序列和时间间隔序列，得到用户下个连续位置的概率序列，而该概率序列表示用户的喜好程度，以此将概率序列映射至 POI 位置序列，并推荐给用户。

### 3 实验与分析

#### 3.1 数据集分析

本文实验使用两套公开的 LBSN 签到数据集，分别为东京地区的 Foursquare 签到数据和纽约地区的 Instagram 签到数据来测试所提出的 OurNet 方法的性能。Foursquare 数据集和 Instagram 数据集的签到信息包含了用户 ID、POI ID、时间、经纬度等信息。Foursquare 数据集数据稀疏度为 97.55%，连续签到最大空间距离为 38.41km；而 Instagram 数据集数据稀疏度为 99.58%，连续签到最大空间距离为 45.62km。为防止实验数据中的用户签到序列过短，致使网络训练精度降低，需要对数据集进行预处理，应满足每个用户至少签到 5 次，每个 POI 至少被签到 5 次。数据集的基本统计信息如表 1：

表 1 数据集统计  
Tab.1 Statistics of the dataset

统计科目	Foursquare	Instagram
用户数	2293	16889

不同 POI 位置	6870	3961
用户签到数	385914	278735
用户平均签到数	168.30	16.50
用户平均访问 POI 个数	55.37	9.54
同一 POI 的平均签到数	56.17	70.37
同一 POI 的平均访问人数	18.48	40.68
数据稀疏度	97.55%	99.58%
连续签到最大空间距离	38.41km	45.62km

分析数据集可知，两个数据集都存在数据稀疏性问题，Foursquare 数据中用户平均签到序列长度大于 Instagram 数据中用户平均签到序列长度。本文在实验时，每个数据集分别设置为训练集和测试集两部分，将签到序列的前 80% 作为训练集，20% 设置作为测试集。

#### 3.2 实验设置与评价指标

本文算法的实验环境是基于 Windows 10 操作系统，Intel(R)Core(TM) Intel i7 8700k CPU、内存 32GB、NVIDIA TX 2080Ti GPU、深度学习框架为 Tensorflow-1.13。本文主要使用召回率 (R)、精确度 (P)、F1 分数 (F) 和归一化折损累计增益 (N) 四个评价指标对实验结果进行评价。召回率反映网络预测正样本的能力；精确度用于评价推荐结果的准确性；F1 分数反映网络的稳定性；归一化折损累计增益为排序结果的评价指标，评价排序的准确性。以上四个指标均为值越大效果越好。

1)  $R@k$  评价指标如公式 (7) 所示：

$$R@k = \frac{1}{n} \sum_{u=1}^n \frac{|y_k^{\text{pre}}(u) \cap y^{\text{label}}(u)|}{|y^{\text{label}}(u)|} \quad (7)$$

2)  $P@k$  评价指标如公式 (8) 所示：

$$P@k = \frac{1}{n} \sum_{u=1}^n \frac{|y_k^{\text{pre}}(u) \cap y^{\text{label}}(u)|}{k} \quad (8)$$

3)  $F@k$  评价指标如公式 (9) 所示：

$$F@k = \frac{1}{n} \sum_{u=1}^n \frac{2 \times |y_k^{\text{pre}}(u) \cap y^{\text{label}}(u)|}{(k + |y^{\text{label}}(u)|)} \quad (9)$$

4)  $N@k$  评价指标如公式 (10) 所示：

$$N@k = \frac{1}{n} \sum_{u=1}^n \frac{1}{Y_u} \sum_{i=1}^k \frac{2^{r(i)} - 1}{\log_2(i+1)} \quad (10)$$

其中， $k$  为推荐序列的长度， $n$  为数据集中用户个数， $y_k^{\text{pre}}(u)$  为用户推荐前  $k$  序列， $y^{\text{label}}(u)$  为用户签到过的 POI 序列， $\cap$  为取交集， $|\cdot|$  为集合中元素的个数， $r(i)$  为推荐序列与真实序列相关性分数， $Y_u$  为归一化正则项。

#### 3.3 与其它算法对比

本文选取 6 个经典和先进的推荐算法作对比实

验, 其中 PRME-G 和 FPMC-LR 为经典的数学模型算法, GRU、NextItNet、STAN 和 STGN 为基于深度学习网络的推荐算法, 各算法介绍如下:

1) PRME-G<sup>[4]</sup>: 一种基于度量学习的 POI 推荐方法, 结合马尔可夫链模型建模用户签到行为。用度量学习代替矩阵分解增强模型表达能力, 考虑地理影响、序列影响。

2) FPMC-LR<sup>[11]</sup>: 一种基于马尔可夫链和用户的移动地理区域约束的连续 POI 推荐方法。考虑地理影响、序列影响, 去除了多余的噪声数据。

3) GRU<sup>[19]</sup>: 一种循环神经网络的稳健变体, 用以建模用户签到的序列关系, 可挖掘用户签到序列关系。

4) NextItNet<sup>[21]</sup>: 引入简单有效的概率生成模型, 且该模型的网络结构为扩张卷积结合残差结构, 简化了深层次网络结构, 优化了模型的训练时间和精度。

5) STAN<sup>[27]</sup>: 一种基于注意力的模型, 它明确地使用用户轨迹中 POI 之间的相对时空信息。

6) STGN<sup>[26]</sup>: 该方法通过添加时间和距离门来整合时间和距离间隔, 对时间和空间上下文进行建模。

### 3.4 实验结果与分析

#### 3.4.1 空间距离与时间间隔影响分析

对两套数据中用户连续签到到时间间隔和空间距离变化分析, 得到图 4 时间间隔分布情况和图 5 空间距离累计分布函数 (CDF) 曲线。由图 4 (a) 和图 4 (b) 可以看出大部分用户连续签到行为主要发生在时间间隔 1 天之内。当连续签到时间间隔大于 1 天时, 用户连续签到数量呈现出急剧下降的趋势。因此, 连续签到时间间隔可作为一项重要的影响因素。

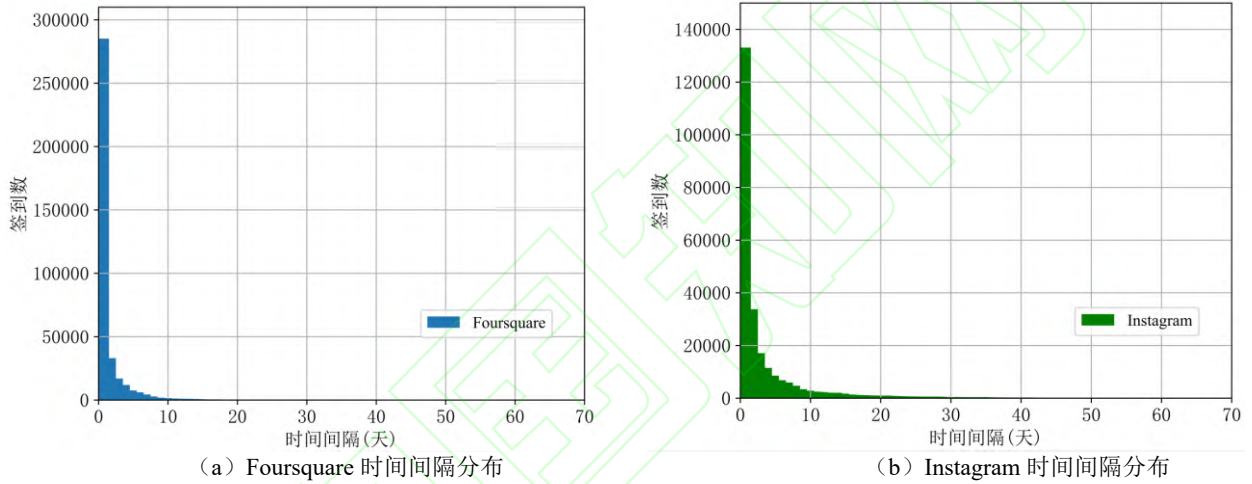


图 4 Foursquare (a) 和 Instagram (b) 的时间间隔分布情况  
Fig.4 Time interval distribution of Foursquare(a) and Instagram(b)

由图 5 可以看出, Foursquare 数据集中有 80% 的连续签到 POI 间的地理路网距离小于 10km, 而 Instagram 数据集中有 90% 的连续签到 POI 间的地理路网距离小于 10km。即当距离小于 10km 的时候, 用户签到的概率更大; 反之, 当距离大于 10km 时, 用户签到的概率更小。由上述分析可得用户连续签到的空间距离和时间间隔对用户签到行为存在影响。

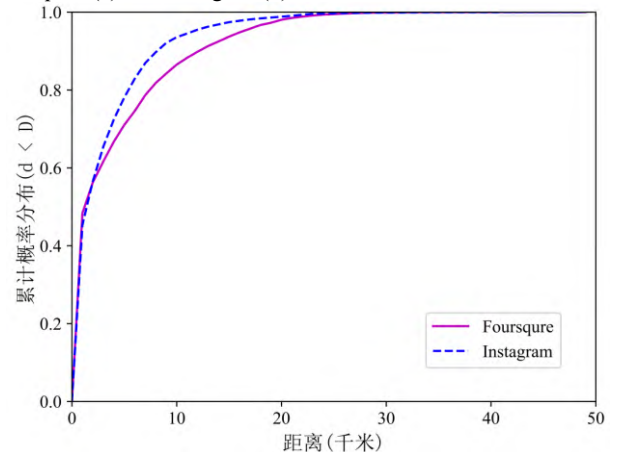


图 5 空间距离累计概率分布函数  
Fig.5 Cumulative distribution function of spatial distance

#### 3.4.2 嵌入维度分析

本节实验主要对网络嵌入维度进行分析, 嵌入维度分别设置为 20、40、60、80、100 和 120 相同



间隔的维度数。本文分别在 Foursquare 和 Instagram 两个不同数据集进行实验，分别得到表 2 和表 3 基于归一化折损累计增益的实验结果。从两个实验结果可以看出，针对不同数据集在不同嵌入维度，本文的网络预测的序列与真实的序列间准确性能力不同。

表 2 在 Foursquare 数据集下不同嵌入维度的归一化折损累计增益

Tab.2 NDCG of different embedding dimensions in the Foursquare dataset

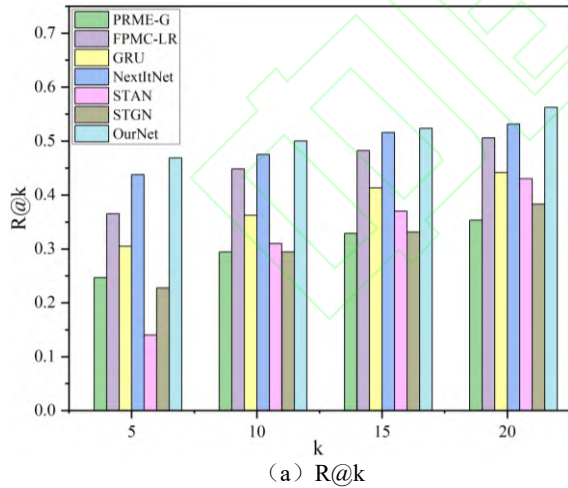
	20	40	60	80	100	120
N@5	0.338	0.324	0.354	0.365	<b>0.381</b>	0.346
	8	1	4	4	<b>6</b>	3
N@1	0.359	0.356	0.375	<b>0.395</b>	0.390	0.361
	3	2	2	<b>1</b>	6	4
N@1	0.367	0.360	0.383	<b>0.395</b>	0.390	0.385
	5	8	7	<b>1</b>	6	6
N@2	0.367	0.364	0.391	0.395	0.398	<b>0.400</b>
	0	5	6	0	1	3
						<b>2</b>

表 3 在 Instagram 数据集下不同嵌入维度的归一化折损累计增益

Tab.3 NDCG of different embedding dimensions in the Instagram dataset

	20	40	60	80	100	120
N@5	0.329	<b>0.406</b>	0.347	0.396	0.365	0.396
	8	<b>3</b>	3	6	1	4
N@1	0.347	<b>0.446</b>	0.367	0.407	0.376	0.406
	9	<b>0</b>	5	6	3	2
N@1	0.356	<b>0.463</b>	0.382	0.424	0.389	0.422
	1	<b>4</b>	8	2	0	4
N@2	0.363	<b>0.470</b>	0.385	0.431	0.410	0.437
	2	<b>5</b>	4	5	6	2

由表 2 可知，针对 Foursquare 数据集，当推荐




序列长度为 5 时，网络准确性能力最好的嵌入维度为 100；当推荐序列长度为 10 和 15 时，网络准确性能力最好的嵌入维度为 80；当推荐序列长度为 20 时，网络准确性能力最好的嵌入维度为 120。但从综合表现能力角度，表现能力最好的嵌入维度为 100。由表 3 可知，针对 Instagram 数据集，在不同推荐序列长度上，网络准确性能力最好的嵌入维度为 40。


### 3.4.3 算法对比与分析

本文提出的算法分别在不同数据集，与不同的算法进行对比实验。在对比实验中，本文算法的学习率为 0.001，迭代次数为 100，由于数据量较大，为减少特征数据中的噪声信息，优化网络的性能及速度，采用分批次处理，且每批次大小为 32。评价指标中  $k$  分别设置为 5、10、15 和 20，测试不同推荐序列长度对算法预测能力的影响。


图 6 为基于 Foursquare 数据的对比实验，与对比算法中表现最好的算法 NextItNet 相比，本文提出的 OurNet 在四个评价指标上都有提升。其中，R@5、10、15、20 分别提升了 7.14%、5.26%、1.52%、5.88%；P@5、10、15、20 分别提升了 7.14%、3.03%、3.03%、5.88%；F@5、10、15、20 分别提升了 7.14%、2.45%、2.93%、5.88%；N@5、10、15、20 分别提升了 24.95%、18.77%、17.46%、17.05%。在定量分析上，N@ $k$  指标提升最为明显，可得出 OurNet 推荐序列的排序准确性在对比算法中是最优的，而在其它三个指标上提升较少，但该算法在预测正样本的能力、稳定性和推荐结果准确性都略优于其它对比算法。







(c)  $F@k$




(d)  $N@k$

图 6 基于 Foursquare 数据的对比实验


Fig. 6 Contrast experiment based on Foursquare data

图 7 为基于 Instagram 数据的对比实验,可以看出本文提出的 **OurNet** 在四个评价指标上的表现能力明显优于其它对比算法。与对比算法中表现最好的算法 **NextItNet** 相比,  $R@5$ 、10、15、20 分别提升了 20.83%、23.08%、17.78%、12.50%;  $P@5$ 、10、15、20 分别提升了 25.00%、11.11%、12.50%、15.625%;


$F@5$ 、10、15、20 分别提升了 24.29%、12.24%、12.84%、15.47%;  $N@5$ 、10、15、20 分别提升了 42.47%、16.08%、19.46%、7.06%。在定量分析上,本文提出的 **OurNet** 在正样本预测能力、模型稳定性和推荐结果准确性上都优于其它六种模型。




(a)  $R@k$



(b)  $P@k$



(c)  $F@k$



(d)  $N@k$

图 7 基于 Instagram 数据的对比实验

Fig. 7 Contrast experiment based on Instagram data

根据图 6 和图 7 实验结果可以看出,在不同数据集上对比算法呈现出不同的表现能力,而本文提出的 OurNet 表现能力相对稳定。由表 1 可知,Instagram 数据的用户数远大于 Foursquare 数据,但 POI 数量、用户签到数和用户的平均签到数量则是 Foursquare 大于 Instagram,说明在 Foursquare 中的 POI 的种类多,用户比较活跃,且连续签到序列的平均长度大于 Instagram,且从用户平均访问 POI 个数可以看出,后者的用户签到 POI 位置相比前者来说比较单一。因此,从实验结果上看, FPMC-LR 更适合用户签到 POI 位置种类较多且具有一定连续签到序列长度的数据集, GRU、PRME-G 和 STAN 则反之,而本文方法可以较好适应两种数据集。对比方法中的 STAN 算法遵循双注意层机制,但未能考虑顺序属性。基于 LSTM 的 STGN 尽管考虑了时间和空间间隔,但无法有效地捕捉 POI 之间长期依赖关系。对比方法中的 PRME-G 和 FPMC-LR 算法,融入地理空间信息和序列信息,但由于马尔科夫链性质影响,使其对长期连续签到预测比较吃力。而 OurNet 综合考虑时空特征对用户移动行为的影响,构建嵌入时空条件的概率生成模型,建立门控扩张残差网络,更易于挖掘用户长期签到行为,可以为用户推荐更好的 POI 签到位置。

## 4 总结与展望

本文通过构建嵌入时空条件的概率生成模型,建立门控扩张残差网络,提出基于门控扩张残差网络的 POI 推荐方法,可以有效地结合时空上下文信息挖掘出用户签到序列的长期依赖关系。经对比实验证明,与 GRU 网络相比扩张卷积与残差网络的网络更适合处理用户签到序列长期依赖的关系,与 NextItNet 相比可知嵌入时间和空间距离特征可以有效帮助模型挖掘用户签到规律。本文提出方法更加适用于挖掘用户连续签到中存在的长期依赖关系,可以有效嵌入空间距离和时间间隔影响因素,提高了 POI 推荐的准确性。本文方法没有考虑社交关系和 POI 类别对推荐结果的影响,在接下来的研究中,可以通过构建包含社交关系和 POI 类别特征变化的图模型,用以刻画用户连续签到行为特征,并结合图神经网络进行学习,挖掘用户签到规律,提高 POI 推荐准确性。

### 参考文献

- [1] Wei Haitao, Li Ke, Hao Xiaohui, et al. Integrating Spatial Relationship into a Matrix Factorization Model for POI Recommendation[J]. Geomatics and Information Science of Wuhan University, 2021, 46, 681–690 (魏海涛, 李柯, 郝晓慧, 等. 融入空间关系的矩阵分解 POI 推荐模型[J]. 武汉大学学报(信息科学版), 2021, 46, 681–690)
- [2] Liu, Y. An Experimental Evaluation of Point-of-Interest Recommendation in Location-based

- Social Networks[C]. Proceedings of the Vldb Endowment, 2017, 10, 1010-1021
- [3] Rendle S, Freudenthaler C, GANTNER Z, et al. BPR: Bayesian Personalized Ranking from Implicit Feedback[C]. Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence, Montreal, Quebec, Canada, 2009:452–461
- [4] Feng S, Li X, Zeng Y, et al. Personalized Ranking Metric Embedding for Next New Poi Recommendation[C]. IJCAI'15 Proceedings of the 24th International Conference on Artificial Intelligence, 2015:2069-2075
- [5] Song Yawei, Si Yali, Liu Wenyuan et al. Point-of-Interest Recommendation Algorithm Incorporating Temporal Features and Collaborative Filtering[J]. Journal of Chinese Computer Systems, 2016,37(06):1153-1158 (宋亚伟,司亚利,刘文远,等. 融合时间特征和协同过滤的兴趣点推荐算法[J]. 小型微型计算机系统, 2016,37(06):1153-1158)
- [6] Bao Xuan, Chen Hongmei, Xiao Qing. Time-integrated Point-of-Interest Collaborative Recommendation Algorithm[J]. Journal of Computer Applications, 2021,41(08):2406-2411 (包玄,陈红梅,肖清. 融入时间的兴趣点协同推荐算法[J]. 计算机应用, 2021,41(08):2406-2411)
- [7] Ren Xingyi, Song Meina, Song Junde. Point-of-Interest Recommendation based on User Check-in Behavior[J]. Chinese Journal of Computers, 2017, 40(01):28-51 (任星怡, 宋美娜, 宋俊德. 基于用户签到行为的兴趣点推荐[J]. 计算机学报, 2017, 40(01):28-51)
- [8] Zhang Guoming, Wang Junshu, Jiang Nan. A Point-of-Interest Recommendation Method Based on Hawkes Process[J]. Acta Geodaetica et Cartographica Sinica, 2018, 47(09):1261-1269 (张国明, 王俊淑, 江南, 等. 关注点推荐算法的霍克斯过程法[J]. 测绘学报, 2018, 47(09):1261-1269)
- [9] He Ying, Wang Zhuoran, Zhou Xu et al. Point-of-Interest Algorithm Incorporating Weighted Matrix Decomposition of Social Geographic Information[J]. Journal of Jilin University(Engineering and Technology Edition) 2022, 1-10 (何颖, 王卓然, 周旭, 等. 融合社交地理信息加权矩阵分解的兴趣点推荐算法[J]. 吉林大学学报(工学版) 2022, 1-10)
- [10] Gao Rong, Li Jing, Li Xuefei, et al. A Personalized Point-of-Interest Recommendation Model via Fusion of Geo-social Information[J]. Neurocomputing, 2018, 273 (17): 159-170.
- [11] Cheng C, Yang H, Lyu M R, et al. Where you like to go next: Successive point-of-interest recommendation[C]. Twenty-Third international

- joint conference on Artificial Intelligence, 2013
- [12] Cai L, Xu J, Liu J, et al. Integrating Spatial and Temporal Contexts into a Factorization Model for POI Recommendation[J]. *International Journal of Geographical Information Science*, 2018, 32(3):524-546
- [13] Fan D, Dong Y, Zhang Y. Satellite Image Matching Method Based on Deep Convolutional Neural Network[J]. *Journal of Geodesy and Geoinformation Science*, 2019, 2(02):90-100
- [14] Jianya G, Shunping J. Photogrammetry and Deep Learning[J]. *Journal of Geodesy and Geoinformation Science*, 2018, 1(1):1-15
- [15] Krizhevsky A, Sutskever I, Hinton G E. Imagenet Classification with Deep Convolutional Neural Networks[J]. *Advances in neural information processing systems*, 2012, 25:1097-1105
- [16] Zhang S, Yao L, Sun A, et al. Deep Learning based Recommender System: A Survey and New Perspectives[J]. *ACM Computing Surveys (CSUR)*, 2019, 52(1):1-38
- [17] Guo Danhuai, Zhang Mingke, Jia Nan, et al. Survey of Point-of-Interest Recommendation Research Fused with Deep Learning[J]. *Geomatics and Information Science of Wuhan University*, 2020, 45(12):1890-1902 (郭旦怀, 张鸣珂, 贾楠, 等. 融合深度学习技术的用户兴趣点推荐研究综述[J]. *武汉大学学报(信息科学版)*, 2020, 45(12):1890-1902)
- [18] Wang X, Liu Y, Zhou X, et al. Long- and Short-Term Preference Modeling Based on Multi-Level Attention for Next POI Recommendation[J]. *International Journal of Geo-Information* 2022, 11, 323
- [19] Cho K, Merriënboer B V, Gulceher C, et al. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[C]. *Conference on Empirical Methods in Natural Language Processing (EMNLP 2014)*, 2014:1724-1734
- [20] Liu Q, Wu S, Wang L, et al. Predicting the Next Location: A Recurrent Model with Spatial and Temporal Contexts[C]. *Proceedings of the AAAI Conference on Artificial Intelligence*, 2016
- [21] Yuan F, Karatzoglou A, Arapakis I, et al. A Simple Convolutional Generative Network for Next Item Recommendation[C]. *Proceedings of the Twelfth ACM International Conference on Web Search and Data Mining*, 2019:582-590
- [22] Li J, Wang Y, McAuley J. Time Interval Aware Self-Attention for Sequential Recommendation[C]. *Proceedings of the 13th International Conference on Web Search and Data Mining*, 2020:322-330
- [23] Shen Z, Zhang Y, Lu J, et al. SeriesNet: A Generative Time Series Forecasting Model[C]. *2018 International Joint Conference on Neural Networks (IJCNN)*, 2018:1-8
- [24] Van den oord A, Dieleman S, Zen H, et al. WaveNet: A Generative Model for Raw Audio[C]. *9th ISCA Speech Synthesis Workshop*, 2016:125-125
- [25] Zhang T, Zhao P, Liu Y, et al. Feature-level Deeper Self-Attention Network for Sequential Recommendation[C]. In *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence {IJCAI-19}*, 2019
- [26] Zhao P, Luo A, Liu Y, et al. Where to go next: A spatio-temporal gated network for next poi recommendation[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2022, 34(5): 2512-2524.
- [27] Luo Y, Liu Q, Liu Z. Stan: Spatio-temporal attention network for next location recommendation[C]. *Proceedings of the Web Conference 2021*. 2021: 2177-2185.
- [28] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]. *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016:770-778

#### 网络首发:

**标题:** 时空序列嵌入门控扩张残差网络的兴趣点推荐

**作者:** 姜涛, 徐胜华, 李晓燕, 张志然, 王勇, 罗安, 何璇

**DOI:** 10.13203/j.whugis20220658

**收稿日期:** 2023-06-04

#### 引用格式:

姜涛, 徐胜华, 李晓燕, 等. 时空序列嵌入门控扩张残差网络的兴趣点推荐[J]. *武汉大学学报(信息科学版)*, 2023, DOI: 10.13203/j.whugis20220658 (JIANG Tao, XU Shenghua, LI Xiaoyan, et al. POI Recommendation of Spatiotemporal Sequence Embedding in Gated Dilatation Residual Network [J]. *Geomatics and Information Science of Wuhan University*, 2023, DOI: 10.13203/j. whugis20220658)



网络首发文章内容和格式与正式出版会有细微差别，请以正式出版文件为准！

---

您感兴趣的其他相关论文：

融合深度学习技术的用户兴趣点推荐研究综述

郭旦怀，张鸣珂，贾楠，王彦桐

武汉大学学报（信息科学版），2020, 45(12): 1890-1902

<http://ch.whu.edu.cn/cn/article/doi/10.13203/j.whugis20200334>

