



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目: 融合全局特征的时空网络兴趣点推荐算法
作者: 李鹏飞, 贺洋, 毋建宏
网络首发日期: 2023-07-19
引用格式: 李鹏飞, 贺洋, 毋建宏. 融合全局特征的时空网络兴趣点推荐算法[J/OL]. 计算机工程与应用.
<https://kns.cnki.net/kcms2/detail/11.2127.TP.20230718.1622.004.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

融合全局特征的时空网络兴趣点推荐算法

李鹏飞¹, 贺洋², 毋建宏²

1.西安邮电大学经济管理学院, 西安 710061

2.西安邮电大学现代邮政学院, 西安 710061

摘要: 随着基于位置社交网络的迅速发展, 兴趣点序列推荐逐渐成为近年来研究热点之一。针对现有推荐方法忽略签到数据中的全局信息, 未充分考虑序列签到数据之间的时空间隔问题, 本文提出一种融合全局特征的时空网络兴趣点推荐算法。该方法利用关系图神经网络获取签到数据异构网络图的全局特征, 将时空门控融入传统门控结构中, 融合全局特征对用户移动行为进行建模, 再引入自注意力机制学习用户偏好向量表示。最后, 在两个真实数据集上进行实验比较与分析, 实验结果表明所提方法推荐性能优于同类算法, 验证了算法的有效性。

关键词: 兴趣点推荐; 门控循环单元; 关联图神经网络; 自注意力机制

文献标志码: A **中图分类号:** TP391 **doi:** 10.3778/j.issn.1002-8331.2303-0168

A spatio-temporal network interest point recommendation algorithm fusing global features

LI Pengfei¹, HE Yang², WU Jianhong²

1.School of Economics and Management, Xi'an University of Posts and Telecommunications, Xi'an 710061, China

2.Modern Postal College, Xi'an University of Posts and Telecommunications, Xi'an 710061, China

Abstract: Recommendation of Point of interest (POI) is one of the most popular topics in Location-Based Social Network (LBSN). The existing recommendation methods do not fully consider the deep influence of the spatial and temporal intervals between sequences of check-in data on the recommended sequences. They ignore the global information in the check-in data and focus on the local preferences in the recent check-in sequence of a single user. To address these problems, this paper proposes a global feature fusion based Spatiotemporal Network (GSTN) interest point recommendation algorithm. The method uses graph neural networks to obtain global features of the heterogeneous network graph of check-in data, and incorporates spatiotemporal gating into the traditional gating structure, fuses global features to model users' mobile behavior, and then introduces a self-attentive mechanism to learn user preference vector representation. Finally, the experiments are carried out on two real datasets. The experiments show that the proposed approach outperforms similar algorithms in terms of recommendation performance and verifies the effectiveness of the algorithm.

Keywords: POI Recommendation; Gated Recurrent Unit; Relational Graph Convolutional Networks; Self-attentive Mechanism

随着移动终端和互联网技术的快速发展, 基于位置的网络服务广泛应用于 Foursquare、Gowalla 及大众点评等社交平台, 极大改变了人们的社交方式^[1]。在这些服务平台上, 用户可随时随地共享自己的行为

基金项目: 国家社科基金后期资助重点项目 (21FGLA004); 陕西省社会科学基金项目 (2019D038); 陕西省教育厅科研计划项目 (21JY116); 西安市科技计划项目 (22NYYF061); 陕西省科技创新团队 (2023-CX-TD-13)。
作者简介: 李鹏飞 (1975-), 男, 博士, 教授, 研究方向: 电商物流大数据挖掘, E-mail: lpf@xupt.edu.cn; 贺洋 (1998-), 通信作者, 男, 硕士, 研究方向: 电商大数据挖掘、时间序列预测, E-mail: 18810780151@163.com; 毋建宏 (1973-), 男, 硕士, 副教授, 研究方向: 社交网络分析, E-mail: 252261707@qq.com。

记录,包括访问地点、体验感受等。截至 2017 年 12 月, Foursquare 已经吸引了超过 5500 万用户, 拥有超过 100 亿次的签到数据^[2], 平台积累了大量的地点标记数据。这些签到数据可为用户兴趣点推荐提供数据基础^[3]。

在传统兴趣点推荐中, 典型的方法是利用协同过滤算法挖掘用户之间的偏好^[4]。协同过滤算法通过分析用户与兴趣点之间的关联规则, 归纳相似用户的偏好, 从而实现兴趣点推荐。但该算法将用户看作静态实体, 不能捕捉到用户偏好的动态变化。综合现有研究可知, 用户签到行为具有较强的时空依赖关系^[5]。如图 1 所示, 用户 1 在访问商场、咖啡馆以及粤菜馆后又去了电影院观影, 其签到行为揭示了用户局部偏好的动态变化, 但仅仅依赖局部动态信息, 对复杂用户的行为偏好表示有限。




图 1 用户签到序列示例

Fig.1 Example of user sign-in sequence

而在现实生活中, 用户的签到序列变化不仅与局部动态偏好有关, 也会受到签到数据中全局静态特征的影响。图 1 中用户 1 先去粤菜馆后去电影院的签到行为与用户 2 一致, 该行为可能与粤菜馆和电影院同处于一个区域有关联, 由此可见在全局签到数据中存在全局特征。而现有方法未能充分挖掘全局签到数据中的全局特征, 无法把握用户的全局偏好, 进而影响兴趣点推荐性能。

基于此, 本文提出了一种融合全局特征的时空网络兴趣点推荐算法 (GSTN, Global feature fusion based Spatiotemporal Network), 该方法将时空动态偏好以及

全局特征融合于用户动态行为建模中。主要工作贡献如下:

(1) 基于用户、兴趣点以及地理区域位置构建联合异构网络图, 利用关系图卷积网络捕捉异构图中的节点全局特征。

(2) 考虑到用户签到序列中时间空间的变化, 在传统门控结构基础上增加时空门控结构。基于全局特征利用时空门控动态捕捉用户签到行为中的时空偏好, 获取包含时空偏好的用户签到行为特征。

(3) 引用自注意力机制捕捉用户签到之间的内在联系, 获取用户局部动态偏好。将全局特征与用户局部动态偏好相结合, 提升兴趣点推荐的性能。

1 相关工作

传统兴趣点推荐大多采用协同过滤算法 (Collaborative Filtering, CF), 通过群体行为来寻找用户和地点的相似性, 进而为用户提供推荐。该算法主要通过矩阵分解及其变体^[6], 分解用户的签到数据, 提取潜在的用户特征矩阵及兴趣点特征矩阵进行推荐^[7]。近年来, 大量基于 CF 的研究将时空信息融入到推荐中, 通过挖掘用户的行为习惯预测用户未来行动。考虑到空间因素, Ye 等^[8]使用贝叶斯协同过滤模型将地理影响融入推荐。Levandovski 等^[9]提出 Travel Penalty 的概念, Travel Penalty 与目标用户到兴趣点的距离呈正相关。Kurashima 等^[10]根据目标用户历史访问的兴趣点主题及用户与历史签到的距离进行推荐。Lian 等^[11]通过加权矩阵将地理信息融入兴趣点推荐, 以提高推荐性能。在时间因素上, Yuan 等^[12]和 Gao 等^[13]在 Ye 模型的基础上融入时间偏好, 以提高模型的性能及准确率。上述研究均将时空信息融入推荐以提高推荐性能, 证明时空信息对于兴趣点推荐的必要性。

随着神经网络在自然语言处理、计算机视觉等领域取得较好的效果, 并考虑到用户签到数据序列性的特点, 大量研究将循环神经网络 (RNN) 应用于兴趣点推荐, 以获取签到数据的顺序信息^[14]。常规 RNN 模型在处理长时间序列时存在梯度爆炸或梯度消失等问题^[15], 其变体长短期记忆 (Long-Short Term Memory, LSTM)^[16]模型和门控循环单元 (Gated Recurrent Unit, GRU)^[17]模型通过添加门控结构来捕捉序列信息的偏好, 能够有效地解决上述问题^[18]。但传统循环神经网络不具备时空感知的能力, 无法对用户的时空偏好进行建模。本文在传统门控结构基础上增加时间、空间门控结构, 融合时间空间信息对用户签到行为进行建模。

针对用户签到数据稀疏的问题,研究者们开始考虑在兴趣点推荐中引入相关辅助数据^[19]。由于异构信息网络可提供丰富的结构信息,能够有效提升推荐的准确率和可解释性,近年来被广泛应用于兴趣点推荐中^[20]。Zhao 等^[21]通过矩阵因子分解实现异构信息的融合。Su 等^[22]利用融合社交关系的异构网络增强用户表示,学习用户以及兴趣点之间的关系。尽管上述方法能够在一定程度提升推荐的准确度,但忽略用户长期稳定的全局静态偏好以及签到数据中隐含的依赖关系,未能有效将全局特征融入用户表示。

2 融合全局特征的时空网络兴趣点推荐算法

与现有兴趣点推荐方法不同,本文提出融合全局特征的时空网络兴趣点推荐算法 GSTN,将签到数据中的全局静态信息与用户签到序列之间的依赖关系进行融合以捕捉复杂的用户偏好,进而提升推荐性能。GSTN 算法主要步骤如下:

(1) 为研究签到数据中实体之间的关联关系,获取全局特征,本研究基于交互数据以及地理信息构建异构网络图 G 。

(2) 对于联合异构图 G ,采用 R-GCN (Relational Data with Graph Convolutional Networks) 算法对图中的各节点进行编码,利用 R-GCN 的消息传递机制学习各类节点的向量表示,获取全局静态特征。

(3) 针对传统循环网络无法捕捉时空偏好的问题,设计一种可根据时间、空间转换进行选择记忆的门控结构 SG-GRU (Spatiotemporal Gated-GRU),并融合全局特征获取用户复杂动态偏好。

(4) 引入自注意力机制对签到地点进行建模,加权获取用户的个性化偏好向量,实现兴趣点推荐。

GSTN 算法的整体框架图如图 2 所示。

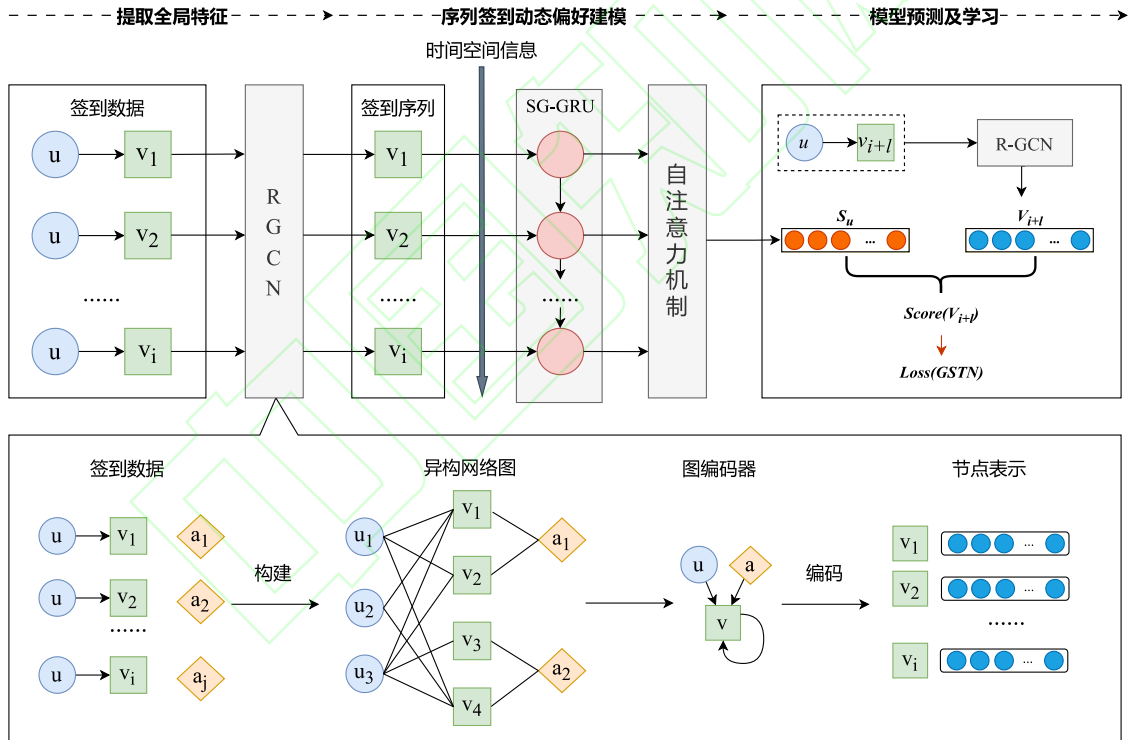


图 2 GSTN 算法框架图

Fig.2 GSTN algorithm framework diagram

2.1 问题定义

设用户集合为 $U = \{u_1, u_2, \dots, u_m\}$, 兴趣点集合为 $V = \{v_1, v_2, \dots, v_i\}$, 相关问题定义如下。

定义 1 (用户签到序列): 对于每个用户 u , 存在一个从 t_1 到 t_i 时间段历史访问的兴趣点序列表示为 $V =$

$\{v_{j1}, v_{j2}, \dots, v_{ji}\}$, 其中 v_{ji} 表示用户 u_j 在 t_i 时间访问的兴趣点。

定义 2 (时间空间间隔): 签到序列对应的时间戳序列以及位置序列分别为 $Ts = \{t_1, t_2, \dots, t_i\}$ 和 $Ls = \{(x_1, y_1), \dots, (x_i, y_i)\}$ 。

定义 3 (异构网络图): 异构网络图表示为 $G = (Ns, Es)$ 。其中 Ns 表示节点实体对象集合, Es 表示两个实体类型之间的交互关系。

问题定义 (融合全局特征的时空网络兴趣点推荐): 对于 $u \in U$, 依据当前时间 t_i 查询到的用户历史访问签到序列 H_i^u 的条件, 预测用户 u 在 t_{i+1} 时刻的兴趣点并向用户推荐。

2.2 基于关系图神经网络的全局特征提取

(1) 构建异构网络图

使用异构图信息网络旨在利用多种类型的上下文信息, 获取目标实体的全局特征, 提高模型性能。在兴趣点推荐中, 现有的基于用户兴趣点交互的推荐方法未能有效捕捉兴趣点之间、用户与地理区域之间的关联关系。为解决该问题, 本文构建用户、兴趣点以及地理区域的异构网络图 $G = (Ns, Es)$, 结构如图 3 所示。将地理区域作为显式嵌入到异构图中能更好的利用空间分布信息, 捕捉用户的移动区域偏好。




图 3 异构网络图

Fig.3 Heterogeneous network diagram

其中 Ns 节点集合由用户节点 ($u \in U$)、兴趣点节点 ($v \in V$) 以及区域节点 ($a \in A$) 组成, Es 边集合包括用户与兴趣点的交互 (u, v) 以及兴趣点与区域的交互 (v, a)。在异构网络图中, 各实体之间建立起传递关系, 该传递关系可由图神经网络捕获。

(2) 基于关系图神经网络的实体编码

图神经网络是基于图结构数据的一种状态转换网络, 通过对中心节点及其邻居节点进行迭代、聚合更新节点的嵌入表示。网络中节点的状态受邻居及高阶邻居节点的影响而变化, 最终达到平衡, 以此学习节点之间的关联信息。

结合异构网络图的特点, 本文利用关系图神经网络 R-GCN 对异构图中节点进行编码。与 GCN 模型不

同, R-GCN 是一种面向异构网络图多关系类型数据的消息传递网络^[23]。利用 R-GCN 对三类实体进行表示学习, 并映射到同一向量空间中。R-GCN 将节点状态更新划分为消息传递和消息聚合两个阶段, 公式如下。

$$t_{j \rightarrow i, e}^{(l)} = \frac{1}{c_{ji}} h_j^{(l)} W_e^{(l)} \quad (1)$$

$$h_{i, e}^{(l+1)} = b^{(l)} + \sum_{j \in N_e(i)} t_{j \rightarrow i, e}^{(l)} \quad (2)$$

$$h_i^{(l+1)} = \sigma \left(\text{aggregate} \{ h_{i, e}^{(l+1)}, \forall e \in E(i) \} \right) \quad (3)$$

式 (1) 中 c_{ji} 为归一化系数, $h_j^{(l)}$ 表示节点 j 在第 l 层的特征向量, $W_e^{(l)}$ 为参数矩阵。节点 i 可以获取来自多个邻居节点的特征信息, 对于这些邻接信息需要经过聚合操作以更新节点表示。在异构网络图中, 聚合更新可分两个步骤进行: 首先如式 (2) 将相同类型的相邻节点特征进行聚合可得到 $h_{i, e}^{(l+1)}$ 。其次对于不同类型聚合向量按照式 (3) 进行聚合激活, 更新节点自身嵌入表示。

式 (2) 中, $h_{i, e}^{(l+1)}$ 表示 $l+1$ 层节点 i 对 e 类型边的邻居节点的聚合向量, $b^{(l)}$ 为偏置项。式 (3) 中, $h_i^{(l+1)}$ 表示节点 i 在 $l+1$ 层的向量表示, σ 为激活函数, 可对嵌入向量进行非线性变化, 增强模型表现力。 aggregate 为聚合函数。本实验采用平均池化函数实现聚合。不同类型节点的消息传递方式如图 4 所示。




图 4 不同类型节点消息传递模式

Fig.4 Different types of node messaging modes

图 4 阐明了三种类型节点的消息传递、聚合与更新方法。本文利用关系图卷积网络 R-GCN 编码器对各个实体进行编码, 得到节点向量表示 $x_i = h_i^{(l+1)}$, 有效建模实体与其高阶邻居之间的关系, 获取实体全局特征。

2.3 融合时空信息的用户行为建模

兴趣点推荐中的用户行为是用户的签到转换, 用户行为建模是捕捉用户签到转换的特征规律, 以应用

于兴趣点推荐。在用户签到转换过程中,除了签到地点的属性特征影响还存在着时间和空间转换的规律。

本文考虑用户签到行为的时序性以及用户签到数据存在时间间隔与空间位置变化转换的特点,将基于R-GCN学习异构关系图提取的签到序列节点特征向量与用户签到的时空信息相结合构建用户行为信息,其信息数据结构如图5所示。其中,每个签到 v_i 信息都包含签到节点的全局特征表示、时间信息 t_i 以及位置信息 (x_i, y_i) 。




图5 用户行为信息结构图

Fig.5 User behavior information structure diagram

针对行为信息的序列性以及时空性,本文基于GRU模型进行用户行为建模。为充分捕捉用户行为的时间变化以及空间位置变化,提出时空门控GRU结构SG-GRU。区别于传统GRU结构通过重置门 r_i 和更新门 z_i 控制信息的保留和遗忘,SG-GRU新增时间门控和空间门控捕捉序列数据的时空偏好,结合重置门和更新门对信息进行遗留处理。SG-GRU模型结构如图6所示。

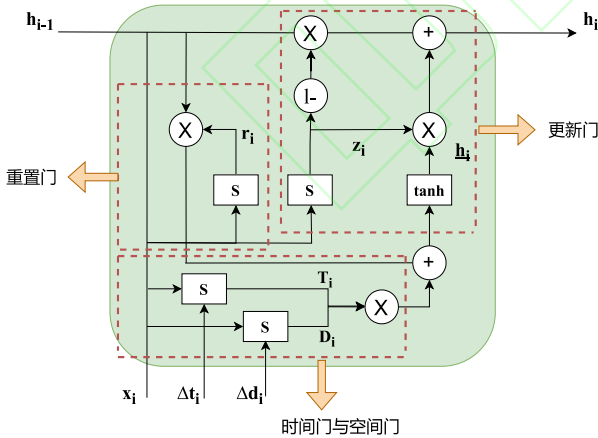


图6 SG-GRU 结构图

Fig.6 SG-GRU structure diagram

其中,SG-GRU的外部输入为 x_i 、 Δt_i 和 Δd_i ,分别表示用户签到节点的全局特征表示、两个签到之间的时间和空间间隔, i 表示当前时刻。 Δt_i 表示当前签到时

刻与上一签到时刻时间间隔权重,由时间间隔与时间比例因子标准化得到, Δd_i 表示当前签到位置与上一签到位置空间距离权重,由两个签到地点的经纬度通过半正矢Haversine公式计算空间距离,经过距离比例因子标准化得到,公式如下。

$$\Delta t_i = \frac{t_i - t_{i-1}}{ts} \quad (4)$$

$$\Delta d_i = \frac{\text{Haversine}(x_i, y_i, x_{i-1}, y_{i-1})}{ds} \quad (5)$$

根据用户签到的时间信息 t 以及空间纬度、经度信息 (x, y) 计算用户签到转换中的时间间隔以及空间间隔。考虑到数据量纲差异,设置 ts 和 ds 比例因子,对时间、空间间隔进行标准化。

在SG-GRU中特征输入 x_i 将直接作用于所有门函数,影响隐藏状态 h_i 的变化。时间空间间隔 Δt_i 和 Δd_i 作用于时间门以及空间门,再通过两个门函数影响 h_i 。SG-GRU各门控公式如下所示。

$$r_i = \sigma_g(W_r x_i + U_r h_{i-1} + b_r) \quad (6)$$

$$z_i = \sigma_g(W_z x_i + U_z h_{i-1} + b_z) \quad (7)$$

$$T_i = \sigma_g(W_t x_i + \sigma_g(U_t \Delta t_i) + b_t) \quad (8)$$

$$D_i = \sigma_g(W_d x_i + \sigma_g(U_d \Delta d_i) + b_d) \quad (9)$$

$$\underline{h}_i = \sigma_h(W_h(x_i \odot T_i \odot D_i) + U_h(r_i \odot h_{i-1}) + b_h) \quad (10)$$

$$h_i = (1 - z_i) \odot h_{i-1} + z_i \odot \underline{h}_i \quad (11)$$

其中: r_i 、 z_i 代表重置门和更新门, T_i 、 D_i 代表时间门和空间门, \underline{h}_i 代表当前时刻的候选状态, h_i 代表当前时刻的隐藏状态, $\{W, U\}$ 均为权重矩阵或向量, σ_g 和 σ_h 分别表示sigmoid和tanh激活函数。区别于传统的GRU,SG-GRU通过设置 T_i 和 D_i 去影响生成当前时刻的候选状态 \underline{h}_i ,最后通过 z_i 实现上一时刻隐藏状态 h_{i-1} 以及当前时刻的选择记忆。在 T_i 和 D_i 中,对于时空间隔较小的地点,其信息应该保留更多,遗忘更少。因此通过设置 U_t 与 U_d 小于0,当 Δt_i 或 Δd_i 越大,由于 $U_t, U_d < 0$, T_i 和 D_i 的值就越小,从而影响当前候选状态 \underline{h}_i 的值就越小,即当前时刻的保留信息就越小。同理,当 Δt_i 或 Δd_i 越小, \underline{h}_i 的值就越大,代表当前时刻的记忆信息越多。

2.4 自注意力机制

鉴于 Transformer 模型在诸多领域中的优异表现，其采用的自注意力机制在序列推荐任务中广泛应用。自注意力机制在动态学习权重的同时，还能捕捉序列实体之间的关联关系，在长序列数据中表现出色。因此本文在 GSTN 中引入自注意力机制，为用户签到序列内的每次访问动态分配权重，公式如下。

$$Q = W_q H \quad (12)$$

$$K = W_k H \quad (13)$$

$$V = W_v H \quad (14)$$

$$s_u = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V \quad (15)$$

其中， $H \in R^{n \times d}$ 表示 SG-GRU 的输出， $W_q, W_k, W_v \in R^{d \times d}$ 分别代表查询 Query、索引 Key 和加权数据 Value 的权重参数， Q, K, V 为对应的权重矩阵。

在式 (15) 中，首先对 Q 和 K 计算相似度，并除以缩放因子 \sqrt{d} 进行缩放点积，再使用 softmax 对相似度进行归一化，最后通过权重对 V 进行加权求和得到顺序感知用户偏好 s_u 。

2.5 模型学习

考虑到兴趣点推荐作为隐反馈推荐模型，基于签到数据，构建正样本及负样本。将签到数据中用户 $i + l$ 时间的访问作为正样本，将用户没有访问的兴趣点随机生成负样本。给定用户签到序列 $C(u)$ ，候选地点 V_c ，其中 V_p 表示正样本， V_m 表示相对于正样本 (u, v) 的负样本。模型损失函数定义为交叉熵损失函数，为了避免模型过拟合，采用 L2 正则化训练模型参数， λ_w 表示正则化系数， W 表示模型参数，公式如式 (16)。

$$Loss_{GSTN} = - \sum_{u \in U} \sum_{(u,v) \in V_p} \left(\ln(y_{(u,v)}) \right) + \sum_{(u,v') \in V_m} \left(\ln(1 - y_{(u,v')}) \right) + \lambda_w \|W\|^2 \quad (16)$$

3 实验与分析

3.1 数据集与评价指标

本文在 Gowalla 和 Foursquare 两个公开的 LBSNs 数据集上开展实验。首先对数据集进行处理，通过数据划分将 70% 的数据用作训练集，10% 的数据用作验证集，剩余的 20% 用作测试集。其次将访问少于 10 个兴趣点的用户和少于 10 个用户访问的兴趣点进行删除，两个数据集的统计信息如表 1 所示。

表 1 LBSNs 签到数据集

Table 1 LBSNs sign-in dataset

Datasets	Users	Locations	Check-ins	Density
Foursquare	2009	4326	75162	0.0087
Gowalla	7744	12948	280263	0.0028

在实验中，采用准确率 $Precision@K$ 以及召回率 $Recall@K$ 作为算法评价指标。其中 K 代表兴趣点的推荐数量，准确率指推荐结果中正确推荐兴趣点数目所占的比例，召回率是指正确推荐兴趣点占用户实际访问兴趣点总数的比例，指标的定义公式如下。

$$Precision = \frac{|R(u) \cap T(u)|}{|R(u)|} \quad (17)$$

$$Recall = \frac{|R(u) \cap T(u)|}{|T(u)|} \quad (18)$$

其中： $R(u)$ 表示模型为用户 u 推荐地点集合， $T(u)$ 表示用户 u 在实际签到地点集合。

3.2 参数设置与对比算法

实验所用到的神经网络学习框架为 Pytorch，超参数学习率 lr 设置为 0.001，L2 正则化惩罚 λ_w 设置为 0.002，批量大小 Batch Size 设置为 30，时间比例因子 t_{scale} 设置为 30，距离比例因子 d_{scale} 设置为 200，模型推荐长度 K 设置为 5，10，20。

实验设置 5 个基线算法，将 GSTN 算法的 Precision 值以及 Recall 值与基线算法进行比较，评估各算法的性能，基线算法如下：

(1) FPMC-LR^[24]: 将 FPMC 提出的个性化马尔可夫链与用户移动约束相结合。用户移动约束指的是用户在移动过程中存在局部区域的约束，模型分解所有用户的转移矩阵张量，并基于马尔可夫链假设计算转移概率，预测下一个地点位置。

(2) LSTM: 长短期记忆结构，包含一个记忆单元和三个门结构，是 RNN 的一个变体，较传统 RNN 能

更好地捕捉长序列之间的依赖关系，在一定程度上解决 RNN 梯度爆炸或消失等问题。

(3) GRU: 门控循环单元, 和 LSTM 同是 RNN 的一个变体, 具备 LSTM 类似功能的选择记忆结构, 通过两个门控结构控制信息流, 并具有参数较少, 易于训练的优点。

(4) ST-RNN^[25]: 在标准 RNN 模型的基础上, ST-RNN 将 RNN 中的单个转移矩阵替换为时间转移矩阵和距离转移矩阵, 模拟时间和空间上下文信息, 使模型具备一定的时空感知能力。

(5) SR-GNN: 一种基于会话的推荐架构, 不仅考虑会话序列之间的复杂结构和依赖关系, 而且能够整合会话的长期偏好和当前兴趣。

3.3 消融实验

本文针对 GSTN 模型进行消融实验, 判断全局信息以及注意力机制对推荐效果的影响, 对比模型变体有:

(1) GSTN-L: 模型不考虑全局信息, 不采用自注意力机制, 仅对序列数据进行用户偏好建模;

(2) GSTN-M: 模型不考虑全局信息, 利用 SG-GRU 对用户行为进行建模并采用注意力机制;

(3) GSTN-N: 模型使用 R-GCN 提取全局信息, 再利用 SG-GRU 对用户行为进行建模不采用注意力机制。

表 2 展示了 3 组实验在数据集 Foursquare 上的对比结果, 图 7 展示了 GSTN 及其三个模型变体间的性能差异。

表 2 消融实验对比结果

Table 2 Comparison results of ablation experiment

model	Precision@5	Recall@5	Precision@10	Recall@10	Precision@20	Recall@20
GSTN-L	0.155	0.072	0.207	0.118	0.22	0.121
GSTN-M	0.167	0.075	0.207	0.121	0.234	0.138
GSTN-N	0.172	0.084	0.212	0.131	0.256	0.149
GSTN	0.196	0.121	0.255	0.147	0.321	0.163

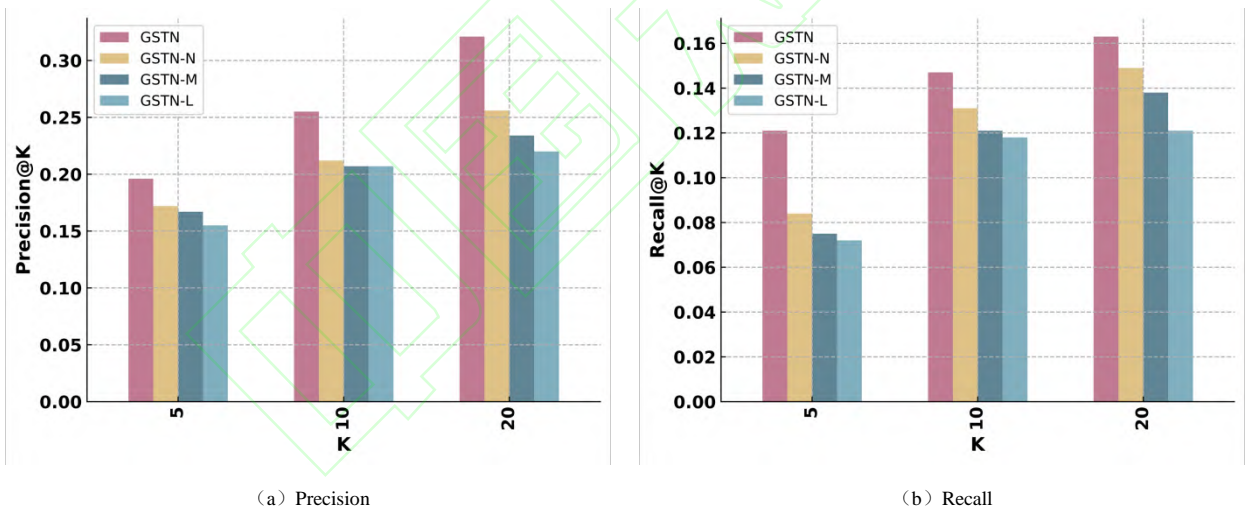


图 7 GSTN 及其变体性能比较

Fig.7 Performance comparison of GSTN and variants

由表 2 和图 7 可知, 不考虑全局特征信息也不采用注意力机制的 GSTN-L 模型, 在推荐效果上性能最差, 其中 GSTN-M、GSTN-N 相比于 GSTN-L 在不同 K 值的 Precision 平均分别提升 4.7%, 9.92%, Recall 平均分别提高 6.92%, 17.82%。GSTN-M 融入注意力机制, 捕捉用户序列之间的关联关系, 可以在一定程度上提高模型性能。GSTN-N 基于异构网络图学习节点全局表示, 融合全局特征对用户签到序列信息进行建模, 在一定程度上能够提升推荐的效果, 验证了融合全局特征的必要性。

将本文 GSTN 模型与变体 GSTN-M、GSTN-N 对比。首先考虑全局信息的 GSTN 与不考虑全局信息的 GSTN-M 相比, GSTN 在模型 Precision 以及 Recall 分别提升 25.91%、33.64%, 模型性能提升显著, 充分验证全局信息对于兴趣点推荐的重要性。其次, 相比 GSTN-N 模型, 引入自注意力机制的 GSTN 推荐效果更优, 其中 GSTN 准确率 precision 平均提升 19.87%, 召回率 recall 平均提升 16.78%。由此可见, 引入自注意力机制虽然在模型性能提升方面较弱于融合全局特

征,但在一定程度上提高模型推荐表现,增强模型抗噪声干扰能力。

3.4 实验分析

本节将从模型性能及参数研究两方面分析模型性能,分别讨论 GSTN 模型的推荐效果以及不同参数设置对模型的影响。

(1) 模型性能对比

GSTN 模型及 5 个基准方法在 Gowalla 和 Foursquare 两个数据集上的准确率 Precision@K 及召回率 Recall@K 结果如表 3、表 4 所示。

表 3 Gowalla 数据集实验结果

Table 3 Gowalla dataset experimental results

model	Gowalla					
	Precision@5	Recall@5	Precision@10	Recall@10	Precision@20	Recall@20
FPMC-LR	0.012	0.011	0.019	0.015	0.031	0.022
LSTM	0.025	0.016	0.031	0.019	0.041	0.026
GRU	0.028	0.017	0.033	0.023	0.047	0.029
ST-RNN	0.029	0.021	0.033	0.024	0.045	0.028
SR-GNN	0.049	0.027	0.069	0.035	0.081	0.054
GTSN	0.061	0.032	0.077	0.041	0.091	0.063

表 4 Foursquare 数据集实验结果

Table 4 Foursquare dataset experimental results

model	Foursquare					
	Precision@5	Recall@5	Precision@10	Recall@10	Precision@20	Recall@20
FPMC-LR	0.019	0.021	0.031	0.029	0.033	0.036
LSTM	0.034	0.037	0.043	0.062	0.078	0.045
GRU	0.035	0.041	0.042	0.062	0.08	0.048
ST-RNN	0.049	0.076	0.051	0.102	0.095	0.081
SR-GNN	0.165	0.112	0.211	0.133	0.275	0.142
GTSN	0.196	0.121	0.255	0.147	0.321	0.163

由表 3 和表 4 可知, FPMC-LR 模型在两个数据集上的推荐效果最差,因为 FPMC-LR 没有考虑签到数据的序列特征。而 LSTM 和 GRU 模型通过长短记忆网络分析签入的序列特征,故二者在准确率和召回率方面均优于 FPMC-LR。

将 ST-RNN 与 LSTM 和 GRU 进行对比,在准确率 Precision 及召回率 Recall 上都有了一定的提升,性能的提高是由于 ST-RNN 融合了时间和空间信息,但没有考虑长短记忆,导致性能提高有限。与 ST-RNN 相比,SR-GNN 推荐模型在精度和 MRR 方面有了很大的

提高。结果表明,门控图神经网络在提高兴趣点推荐性能方面具有明显优势。

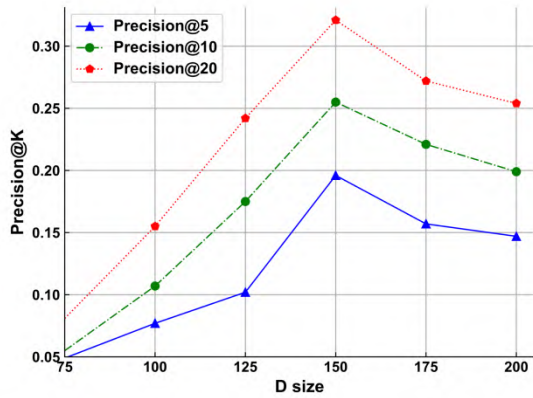
对比最优基线算法 SR-GNN, GTSN 在准确率 Precision 及召回率 Recall 上平均提升了 17.47%, 14.27%,模型推荐性能表现为最优。在 GTSN 模型中,通过 R-GCN 捕捉异构网络图中节点全局特征,结合签到序列信息对用户移动偏好进行建模,集成到自注意力机制中,获取用户移动偏好的向量偏好。上述结果表明, GTSN 可以提高兴趣点推荐的精度和有效性。

(2) 参数研究

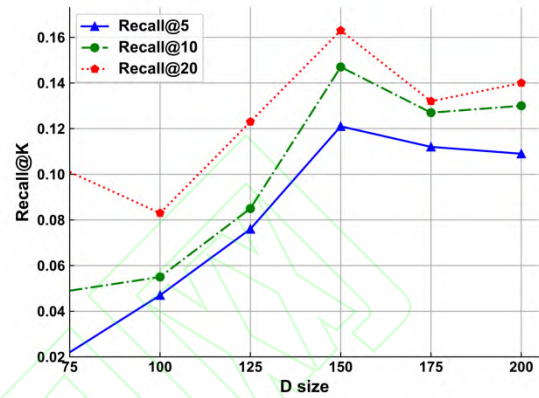
为充分探讨 GTSN 模型受嵌入向量维度大小 D ，负样本数量 $nums$ 以及批量大小 $batch_size$ 的影响状况。下面将针对三个参数设计实验，分析参数对模型性能的影响。

1) 嵌入向量维度实验分析

特征嵌入向量维度大小对于模型的推荐结果有着很大影响，较高的维度的特征向量具有更好的特征表达能力，但也存在过拟合和训练难度的问题。以 Foursquare 数据集为例，在不同推荐 K 值下，不同嵌入向量维度 D 的准确率和召回率如图 8 所示。




(a) Precision



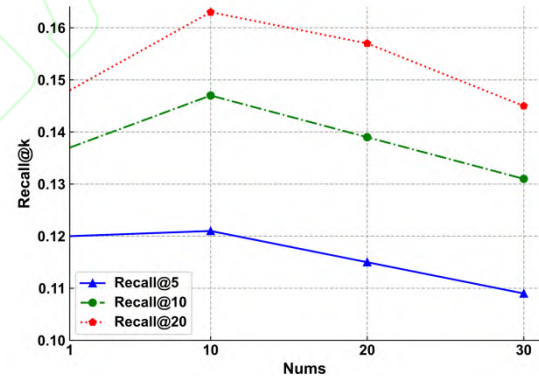
(b) Recall

图 8 不同嵌入向量维度对比实验

Fig.8 Comparison experiments of different embedding vector dimensions



(a) Gowalla 数据集



(b) Foursquare 数据集

图 9 不同负样本数量对比实验

Fig.9 Comparison experiments with different negative sample sizes

图 8 展示了不同嵌入向量维度大小的实验结果。当 $75 \leq D_size < 150$ 时，随着维数的增加，模型 Precision 和 Recall 逐渐增加。当 $150 < D_size \leq 200$ 时，随着维数的增加，模型 Precision 和 Recall 呈下降趋势。当 D_size 取 150 时，模型的 Precision 和 Recall 为最大值。结果表明，嵌入向量维度大小的增加在某一特定范围内改善模型的性能。

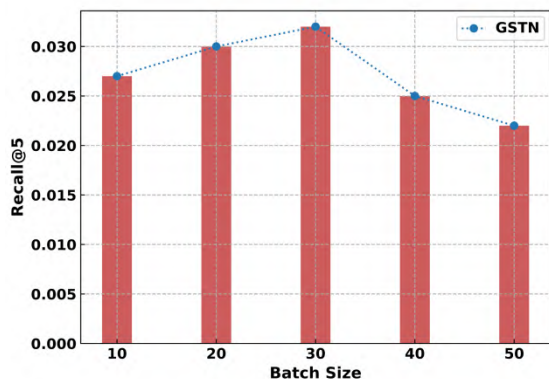
2) 负样本数量实验分析

为研究模型推荐性能对负样本数量的敏感性，基于 Gowalla 和 Foursquare 数据集，分别设置负样本数量 $nums = \{1, 10, 20, 30\}$ ，不同负样本数量在两个数据集上不同 K 值的 Recall 值如图 9 所示。

由图 9 可知，当负样本数量取 10 时，两个数据集都能实现较好的推荐效果。当负样本数量超过阈值时，模型召回率缓慢降低。由于 Gowalla 数据集比 Foursquare 数据集拥有更大的用户及兴趣点数量，数据

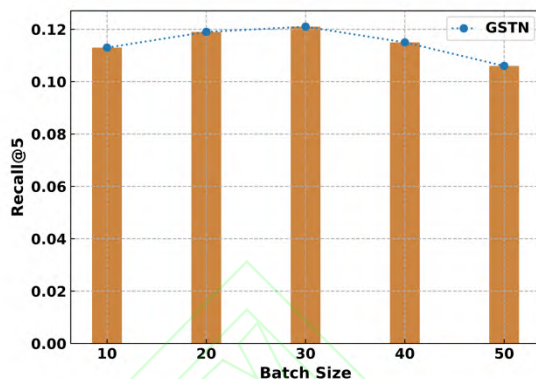
更加稀疏,其对负样本数量的敏感性较低。根据图 9 的对比实验结果,最优负样本数量取 10。

3) 不同批量实验分析



(a) Gowalla 数据集

在模型训练过程中,样本批处理大小也会影响推荐的性能。基于两个数据集,设置不同的批量大小 $batch_size = \{10, 20, 30, 40, 50\}$,在不同批次下的模型推荐 Recall@5 值如图 10 所示。



(b) Foursquare 数据集

图 10 不同批量实验结果对比实验

Fig.10 Comparison experimental results of different batch sizes

图 10 中随着批次大小的逐渐增加, GSTN 推荐算法的 Recall 值先增加后减少。当批次处理大小的值为 30 时,模型推荐 Recall 值取最大,本实验模型批次大小设置为 30。

4 结语

本文在实现 LBSN 中的兴趣点推荐时,重点考虑签到数据中的全局特征,结合时空门控结构和自注意力机制,提出融合全局特征的时空网络兴趣点推荐算法。首先构建异构网络图,通过 R-GCN 获取实体的全局表示;然后设计时空门控结构,将时间空间信息融入传统的门控结构中,捕捉用户行为时空偏好;最后引入自注意力机制学习用户签到序列的顺序关系,建模用户移动行为,进而评估用户访问兴趣点概率,实现下一个兴趣点推荐。实验结果表明,与传统同类方法相比,本文提出的 GSTN 方法多个指标均优于基线方法,全局特征及自注意力机制能有效改善兴趣点推荐效果。

融合全局特征的时空网络兴趣点推荐算法在模型冷启动以及关注机制方面还存在一定的提升空间。在未来研究中,可以利用先验数据制定策略,提出冷启动方案,并整合社交网络形成更有效的关注机制,结合相关的表示技术进一步提高地点推荐的性能。

参考文献:

- [1] 郭旦怀,张鸣珂,贾楠,等.融合深度学习技术的用户兴趣点推荐研究综述[J].武汉大学学报(信息科学版),2020, 45(12):1890-1902.
- [2] GUO D H, ZHANG M K, JIA N, et al. Survey of Point-of-Interest Recommendation Research Fused with Deep Learning[J]. Geomatics and Information Science of Wuhan University, 2020, 45(12): 1890-1902.
- [3] Li Q, Xu X, Liu X, et al. An Attention-Based Spatiotemporal GGNN for Next POI Recommendation[J]. IEEE Access, 2022, 10: 26471-26480.
- [4] FENG S, CONG G, AN B, et al. 2017. POI2Vec: geographical latent representation for predicting future visitors [M]. Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence. AAAI Press; San Francisco, California, USA: 102-108.
- [5] Hu R, Lu X, Liu C, et al. Why we go where we go: Profiling user decisions on choosing POIs[C]. Proceedings of the Twenty-Ninth International Conference on International Joint Conferences on Artificial Intelligence. 2021: 3459-3465.
- [6] 孟祥武,李瑞昌,张玉洁,等.基于用户轨迹数据的移动推荐系统研究[J].软件学报,2018,29(10).
- [7] MENG X W, LI R C, ZHANG Y J, et al. Survey on Mobile Recommender Systems Based on User Trajectory Data[J]. Journal of Software, 2018, 29(10).
- [8] Mnih A, Salakhutdinov R R. Probabilistic matrix factorization[J]. Advances in neural information processing systems, 2007, 20.
- [9] CHENG C, YANG H, KING I, et al. Fused matrix factorization with geographical and social influence in location-based social networks [M]. 2012 Proceedings of the Twenty-Sixth AAAI Conference on Artificial Intelligence. AAAI Press; Toronto, Ontario, Canada: 17-23.
- [10] Ye M, Yin P, Lee W C, et al. Exploiting geographical influence for collaborative point-of-interest recommendation[C]. Proceedings of the 34th international

- ACM SIGIR conference on Research and development in Information Retrieval. 2011: 325-334.
- [9] Levandoski J J, Sarwat M, Eldawy A, et al. Lars: A location-aware recommender system[C]. 2012 IEEE 28th international conference on data engineering. IEEE, 2012: 450-461.
- [10] Kurashima T, Iwata T, Hoshida T, et al. Geo topic model: joint modeling of user's activity area and interests for location recommendation[C]. Proceedings of the sixth ACM international conference on Web search and data mining. 2013: 375-384.
- [11] Lian D, Zhao C, Xie X, et al. GeoMF: joint geographical modeling and matrix factorization for point-of-interest recommendation[C]. Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining. 2014: 831-840.
- [12] Yuan Q, Cong G, Ma Z, et al. Time-aware point-of-interest recommendation[C]. Proceedings of the 36th international ACM SIGIR conference on Research and development in information retrieval. 2013: 363-372.
- [13] Gao H, Tang J, Hu X, et al. Exploring temporal effects for location recommendation on location-based social networks[C]. Proceedings of the 7th ACM conference on Recommender systems. 2013: 93-100.
- [14] Quadrana M, Karatzoglou A, Hidasi B, et al. Personalizing session-based recommendations with hierarchical recurrent neural networks[C]. proceedings of the Eleventh ACM Conference on Recommender Systems. 2017: 130-137.
- [15] 陈建廷, 向阳. 深度神经网络训练中梯度不稳定现象研究综述[J]. 软件学报, 2018, 29(07): 2071-2091.
CHEN J T, XIANG Y. Survey of Unstable Gradients in Deep Neural Network Training[J]. Journal of Software, 2018, 29(07): 2071-2091.
- [16] Graves A. Long short-term memory[J]. Supervised sequence labelling with recurrent neural networks, 2012: 37-45.
- [17] Chung J, Gulcehre C, Cho K H, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. arXiv preprint arXiv:1412.3555, 2014.
- [18] 李全, 李书明, 许新华, 向丹丹, 等. 融合时空信息的双向 GRU 下一个地点推荐[J]. 小型微型计算机系统, 2021, 42(07): 1402-1406.
LI Q, LI S, XU X, XIANG D D, et al. Next Location Recommendation Based on Bi-directional GRU Confusing Space and Time Information [J]. Journal of Chinese Computer Systems, 2021, 42(07): 1402-1406.
- [19] Yuan Q, Cong G, Sun A. Graph-based point-of-interest recommendation with geographical and temporal influences[C]. Proceedings of the 23rd ACM international conference on conference on information and knowledge management. 2014: 659-668.
- [20] Zhang Y, Chen X. Explainable recommendation: A survey and new perspectives[J]. Foundations and Trends® in Information Retrieval, 2020, 14(1): 1-101.
- [21] Zhao H, Yao Q, Li J, et al. Meta-graph based recommendation fusion over heterogeneous information networks[C]. Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining. 2017: 635-644.
- [22] Su Y, Li X, Zha D, et al. HREC: heterogeneous graph embedding-based personalized point-of-interest recommendation[C]. Neural Information Processing: 26th International Conference, ICONIP 2019, Sydney, NSW, Australia, December 12–15, 2019, Proceedings, Part III 26. Springer International Publishing, 2019: 37-49.
- [23] Schlichtkrull M, Kipf T N, Bloem P, et al. Modeling relational data with graph convolutional networks[C]. The Semantic Web: 15th International Conference, ESWC 2018, Heraklion, Crete, Greece, June 3–7, 2018, Proceedings 15. Springer International Publishing, 2018: 593-607.
- [24] Cho E, Myers S A, Leskovec J. Friendship and mobility: Friendship and mobility: User movement in location-based social networks friendship and mobility[C]. User Movement in Location-Based Social Networks ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD). 2011.
- [25] Liu Q, Wu S, Wang L, et al. Predicting the next location: A recurrent model with spatial and temporal contexts[C]. Thirtieth AAAI conference on artificial intelligence. 20