


融合时间和地理信息的兴趣点推荐研究

赵薇,李建波,吕志强,董传浩

(青岛大学计算机科学技术学院,山东 青岛 266071)



摘要:在兴趣点推荐任务中,数据的严重稀疏性限制了模型的推荐性能,并且现有工作忽略了用户在不同时间段访问行为的差异性。针对上述问题,提出了一种融合时间和地理信息的兴趣点推荐模型。该模型首先通过循环神经网络联合学习多种因素;然后利用地理关系模块捕获轨迹中的地理影响。最后,通过一个统一的框架,针对用户工作日和节假日的不同出行需求,推荐不同的访问地点。实验证明,所提模型在兴趣点推荐表现上优于现有模型。

关键词:兴趣点推荐;位置社交网络;循环神经网络;卷积神经网络

中图分类号: TP391

文献标识码: A

Research on Point-of-interest Recommendation Incorporating Time and Geographical Information

ZHAO Wei, LI Jianbo, LÜ Zhiqiang, DONG Chuanhao

(College of Computer Science and Technology, Qingdao University, Qingdao 266071, China)

Abstract: The extreme sparsity of data limits the recommendation performance of the model in point-of-interest (POI) recommendation task. And the existing work ignores the differences of users' movement in different time periods. To solve the above problems, this paper proposes a POI recommendation model that incorporates time and geographical information. Firstly, the model learns multiple factors through recurrent neural network. Then the geographical relationship module is used to capture the geographical influence in the trajectory. Finally, through a unified framework, different POIs are recommended according to the different visit needs of users on weekdays and holidays. Experimental results demonstrate that the proposed model achieves better recommendation performances than the state-of-the-art methods.

Key words: POI recommendation; location-based social network; recurrent neural network; convolutional neural network

0 引言

随着智能手机和平板电脑等带GPS定位的移动终端设备的普及,位置社交网络(Location-Based Social Network, LBSN)得到了快速发展,用户可以轻松地获取已访问兴趣点的地理信息,并进行实时签到。由此产生了海量的签到数据,引起了学者的广泛关注^[1-5]。如何从海量的签到数据中筛选出用户感兴趣的内容是一个值得研究

收稿日期:2021-06-15;修回日期:2021-09-10

基金项目:国家重点研发计划重点专项项目(2018YFB2100303);山东省高等学校青创科技计划创新团队项目(2020KJN011)

第一作者:赵薇(1996-),女,山东济宁人,硕士研究生,主要研究方向为数据挖掘、轨迹预测。

通信作者:李建波(1980-),男,山东昌邑人,博士,教授,主要研究方向为城市计算和智慧交通、机会网络中的数据分流。

的问题。对于兴趣点推荐的研究则可以解决这一难题。兴趣点推荐是一项致力于从大量的候选位置中为用户推荐满足其访问需求的兴趣点的研究,它既可以帮助用户制定合理的出行计划,探索未知的地理区域;也可以帮助商家向潜在的用户提供个性化服务,提高其营业收入;同时可以让政府提前进行交通规划,避免出行高峰期造成的道路阻塞。

现阶段,关于兴趣点推荐的研究主要是根据历史签到数据,挖掘用户潜在的移动模式,模拟用户访问下一个地点的决策过程,达到为用户推荐满足其访问要求的兴趣点的目的^[6]。不同于传统的推荐任务,兴趣点推荐是一个融合时间和地理信息的推荐。例如,用户在每天早晨 8 点去早餐店吃早餐,在工作日下午 3 点去咖啡店买咖啡,在每周日晚上 7 点和朋友去电影院看电影。对于即将到来的一天,如何为用户合理地安排行程,推荐其感兴趣的地点。这时的兴趣点推荐任务一定是融合时间和地理信息的推荐。

在融合时间信息的兴趣点推荐工作中,He 等^[7]认为用户与兴趣点交互的时间戳是有规律的,它不仅是用户访问兴趣点的时间节点,还隐藏着用户访问行为的周期性特征。因此,时间信息在兴趣点推荐中起着重要作用^[8]。Zhao 等^[9]通过门控机制来捕获两个相邻兴趣点之间的访问时间间隔。Feng 等^[10]提出注意力机制来捕获具有周期性特征的时间信息。另外,在融合地理信息的兴趣点推荐工作中,考虑到兴趣点之间的距离,Cheng 等^[11]将地理信息作为一种区域约束,结合马尔可夫链,提出了 FPMC-LR 模型。Sun 等^[12]提出了一个针对短期建模的地理空洞循环神经网络模型,该模型解决了已访问兴趣点在地理上分散的问题。Lian 等^[13]通过用户访问兴趣点的地理信息来捕捉用户访问行为的空间聚类现象。

综上所述,现有方法在一定程度上提高了兴趣点推荐准确率,但忽略了时间和地理信息之间的关系。虽然按时间周期对签到记录进行了划分,但忽略了不同时间用户访问行为受地点距离约束程度的差异性。例如,工作日用户的访问行为受区域限制较大,访问地点受距离约束严重;节假日用户的访问行为相对自由,访问的地点受距离约束程度相对较轻,访问的地点更具有随机性。

针对上述问题,本文对签到数据进行了工作日和节假日的划分,提出了一种融合时间和地理信息的兴趣点推荐模型。该模型主要分为两个部分:一是利用长短期记忆网络(Long Short-Term Memory, LSTM)提取当前轨迹中序列特征的时空关系模块;二是学习历史轨迹中地理信息的地理关系模块。在地理关系模块中,利用卷积神经网络捕获用户的局部地理偏好;根据用户之间的访问相似度,生成关于地理位置的评分矩阵。融合上述两部分,获得用户下一步访问兴趣点的推荐意见。

1 预备知识

1.1 兴趣点推荐

兴趣点推荐被认为是推荐领域中的一个重要任务。与传统的电影、音乐、新闻等推荐任务不同,兴趣点推荐需要用户去访问物理世界中真实存在的地点,因此推荐难度更大。在基于传统方法的研究中,协同过滤算法是被普遍认可的^[14-16]。Ye 等^[17]基于用户的协同过滤框架,采用线性插值的方法,结合地理与社会影响进行兴趣点推荐。夏英等^[18]先通过协同过滤算法模拟用户的社交关系,然后通过加权矩阵分解学习地理信息,进而将两者融合进行兴趣点推荐。另外,由于签到数据是连续的序列数据,因此采用马尔可夫链也可以很好地计算签到序列之间的转移概率。

近年来,深度学习的发展极大地推动了兴趣点推荐的研究。针对签到数据的特点,循环神经网络(Recurrent Neural Network, RNN)及其变体(LSTM、GRU)在兴趣点推荐领域的应用十分广泛。Zhong 等^[19]利用 LSTM 基于流行度和社交网络进行兴趣点推荐。Liu 等^[20]利用 GRU 基于类别感知进行推荐工作。Liu 等^[21]扩张了 RNN,使用时间转移矩阵和距离转移矩阵来分别捕获时空上下文信息,并采用线性插值的方法缓解数据稀疏带来的影响。另外,卷积神经网络(Convolutional Neural Network, CNN)既可以从评论内容中获取语义和情感信息^[22],也可以从最相似的友谊关系图中提取特征^[23],因此在兴趣点推荐中得到了广泛应用。

1.2 兴趣点推荐问题定义

给定一组用户 $U = \{u_1, u_2, \dots, u_{|U|}\}$, $|U|$ 表示数据集中用户的数量;给定一组兴趣点 $L = \{l_1, l_2, \dots, l_{|L|}\}$, $|L|$ 表示数据集中兴趣点的数量。每个兴趣点都有唯一的经纬度标识(lon_l, lat_l),用户的签到记录表示成时空点 q , q 是一个包括兴趣点 l 和时间戳 t 的元组,即 $q = (l, t)$ 。用户的签到轨迹由用户一天中所有的签到记录组成,即 $S = \{q_1, q_2, \dots, q_t\}$ 。已知用户 u 的当前轨迹 $S_T^u = \{q_1^u, q_2^u, \dots, q_t^u\}$, 历史轨迹 $H_{T-1}^u =$

$\{S_1^u, S_2^u, \dots, S_{T-1}^u\}$, 个性化的兴趣点推荐问题是根据已知的用户 u 的轨迹信息, 为用户 u 推荐 t 时刻最合适的访问兴趣点 l 。

2 融合时间和地理信息的兴趣点推荐模型

图 1 展示了所提模型的总体架构, 它主要由时空关系模块、地理关系模块和预测模块三部分组成。

2.1 时空关系模块

当前轨迹中的序列信息(位置、时间)反映了用户最近一段时间内的兴趣偏好, 直接影响用户下一步的决策过程。因此, 将当前轨迹中的不同信息通过嵌入学习, 映射成对应的嵌入向量。然后, 将时空嵌入向量进行连接, 利用 LSTM 学习当前轨迹中的时空转换规律。计算公式为

$$\mathbf{e}_{lt} = \mathbf{e}_{loc}^t \oplus \mathbf{e}_{time}^t, t \in \{1, 2, \dots, |S_T^u|\} \quad (1)$$

$$\mathbf{h}_t = \text{LSTM}(\mathbf{e}_{lt}, \mathbf{h}_{t-1}) \quad (2)$$

其中, $\mathbf{e}_{loc}^t \in \mathbf{R}^{D_l \times 1}$ 为当前轨迹中 t 时刻访问的兴趣点 l_t 的嵌入向量, $\mathbf{e}_{time}^t \in \mathbf{R}^{D_t \times 1}$ 为当前轨迹中时刻 t 的嵌入向量, D_l, D_t 分别为兴趣点和时间的嵌入维度, \oplus 表示连接, $\mathbf{e}_{lt} \in \mathbf{R}^{D_{lt} \times 1}$ 为地点和时间的联合嵌入向量, $D_{lt} = D_l \oplus D_t$, \mathbf{h}_t 表示隐藏状态。

2.2 地理关系模块

2.2.1 时间判别器

考虑到用户的出行受时间和距离的影响程度不同, 本文将签到数据按时间划分为工作日轨迹和节假日轨迹。在数据预处理时, 为了减小训练量, 提高训练效率, 仅保留签到时间的“时”, 作为该条记录的时间, 例: “2021-7-1 12:34:23”, 仅保留“12”作为该条签到记录的时间标签。为了区分工作日轨迹和节假日轨迹, 令工作日的签到时间 $t^{\text{day}} = t, 0 \leq t^{\text{day}} < 24$, 节假日的签到时间 $t^{\text{end}} = t + 24, 24 \leq t^{\text{end}} < 48$ 。在将轨迹输入到地理关系模块之前, 先根据当前轨迹的第一条签到记录判断该轨迹是工作日签到还是节假日签到, 然后选择对应的历史轨迹。即: 若 $t_0 < 24$ 成立, 则选取历史轨迹中属于工作日的签到轨迹, 反之, 选择属于节假日的签到轨迹。另外, 需要判断获得的历史轨迹是否为空, 这样做可以排除已知的历史轨迹中仅包含某一种时间轨迹, 而当前轨迹是另一种时间轨迹的情况, 如: 历史轨迹全部是节假日轨迹, 而当前轨迹是工作日轨迹。针对这一情况, 可以随机生成一个集合 $P = \{l_1, l_2, \dots, l_{|P|}\}$ 作为历史轨迹, $|P|$ 为集合的长度。

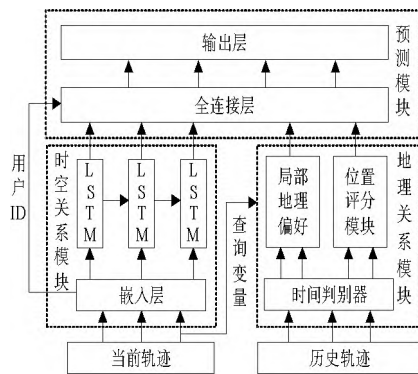


图 1 兴趣点推荐模型

Fig.1 POI recommendation model

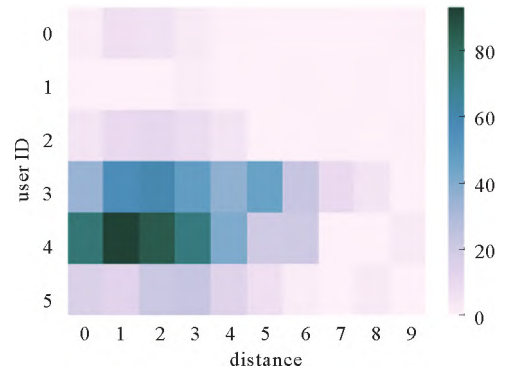


图 2 邻居兴趣点访问次数

Fig.2 Number of visits to neighbor POIs

2.2.2 局部地理偏好模块

由于邻居兴趣点的距离可以满足用户的时间可行性, 用户下一步访问的兴趣点, 极大概率是当前兴趣点的邻居兴趣点。图 2 为邻居兴趣点访问次数的分布图。可以看出: 给定用户访问的兴趣点 l_i , 用户访问 l_i 的次数与访问 l_i 邻居的次数呈正相关, 与距离呈负相关(颜色深浅表示访问次数, 颜色越深表示访问次数越多)。

因此, 根据距离, 对时间判别器的输出结果进行筛选, 生成更小的兴趣点候选集合 Q 。这里需要分别计算历史轨迹中的每一个兴趣点 $l_i, i \in \{1, 2, \dots, |P|\}$ 与当前轨迹中 $t-1$ 时刻访问的兴趣点 l_{t-1} 的距离:

$$d_i = \sqrt{(\text{lon}_{l_i} - \text{lon}_{l_{t-1}})^2 + (\text{lat}_{l_i} - \text{lat}_{l_{t-1}})^2} \quad (3)$$

其中, (lon_{l_i}, lat_{l_i}) 为历史轨迹中第 i 个兴趣点的经纬度, $(lon_{l_{t-1}}, lat_{l_{t-1}})$ 为当前轨迹中 $t-1$ 时刻的兴趣点 l_{t-1} 的经纬度。若 $d_i < \Delta d$ 成立 (Δd 为距离阈值), 则将兴趣点 l_i 添加到新的兴趣点候选集合 Q 中。新生成的兴趣点候选集合 Q 的长度要比历史轨迹的长度短很多, 这样做既可以减少后续计算的成本花费, 也可以避免某些距离较远的兴趣点对预测结果的影响。

为了进一步获得邻居兴趣点的地理特征, 将兴趣点候选集合 Q 嵌入后可以得到 Q_e , 然后通过卷积神经网络实现特征提取, 如图 3 所示。

$$Z = \text{ReLU}(f_{\text{conv}}(Q_e)) \quad (4)$$

其中, $f_{\text{conv}}(Q_e)$ 表示对 Q_e 进行卷积操作, Z 是卷积后的特征图。然后经过一个平均池化层对 Z 降维, 经过全连接层后输出 \hat{Z} 。该模块可以获得用户最近访问的兴趣点在历史轨迹中所有邻居兴趣点的地理特征, 了解用户对于下一个兴趣点在距离上的接受程度。

2.2.3 位置评分模块

该模块主要是根据用户的历史轨迹, 计算不同用户之间已访问兴趣点的相似度, 进一步生成用户关于兴趣点的评分矩阵。

$$c_{u_i}^k = \frac{\sum_{j \in |U|} \omega_{ij} \star a_k}{\sum_{j \in |U|} \omega_{ij}}, k \in \{1, 2, \dots, |L|\} \quad (5)$$

$$\omega_{ij} = \frac{|L_H^{u_i} \cap L_H^{u_j}|}{|L_H^{u_i} \cup L_H^{u_j}|}, i, j \in \{1, 2, \dots, |U|\} \quad (6)$$

其中, $c_{u_i}^k$ 表示用户 u_i 对兴趣点 k 的评分, $a_k = 1$ 表示用户 u_i 访问过兴趣点 k , $a_k = 0$ 表示用户 u_i 未访问过兴趣点 k , ω_{ij} 表示用户 u_i 和用户 u_j 访问兴趣点的相似度, 如式 (6) 所示, $L_H^{u_i}$ 表示用户 u_i 访问过的兴趣点, $L_H^{u_j}$ 表示用户 u_j 访问过的兴趣点, $|L_H^{u_i} \cap L_H^{u_j}|$ 表示用户 u_i 和用户 u_j 访问过的相同兴趣点个数, $|L_H^{u_i} \cup L_H^{u_j}|$ 表示用户 u_i 和用户 u_j 访问过的兴趣点总数。通过上述过程, 计算出用户 u_i 对所有兴趣点的评分矩阵 C_{u_i} , 了解用户对于兴趣点的偏爱程度, 可以更准确地为用户推荐符合其个性化需求的兴趣点。

2.3 预测模块

预测模块由一个全连接层和一个输出层组成。全连接层将时空关系模块和地理关系模块的所有特征结合到一个新的向量中, 并进一步将特征向量处理成一个维度更小、更具有表征意义的向量。然后, 由输出层经过负采样后, 输出预测结果。具体过程如下:

首先, 将当前轨迹中的时空依赖 h_t 和局部地理偏好模块输出的 \hat{Z} 进行聚合。然后, 将个性化信息考虑在内, 生成包含用户个性化信息的高维向量, 即

$$y = (h_t \oplus \hat{Z}) \oplus e_u \quad (7)$$

其中, y 是一个融合时序特征、地理特征及用户个性化特征的向量, 将其与评分矩阵做最后的融合, 并经过 softmax 层处理后, 得到模型预测输出, 如式 (8) 所示:

$$\text{out} = \text{softmax}(y \star W' \star C_{u_i}) \quad (8)$$

其中, W' 是一个可训练矩阵。out 表示概率分布, 概率最大的兴趣点是用户最有可能访问的位置。如果用户真实访问是兴趣点 l_i , 其对应的概率为 p_{l_i} , 那么损失函数可以表示为

$$\text{loss} = - \sum_i^N \log(p_{l_i}^i) \quad (9)$$

其中, N 为训练集中样本的数量, $p_{l_i}^i$ 为对第 i 个真实训练样本的预测概率。

3 实验

3.1 实验数据

本文所用的数据集分别来自 Foursquare、Weeplaces 和 Gowalla。其中, Foursquare 数据集收集了 2012 年 4

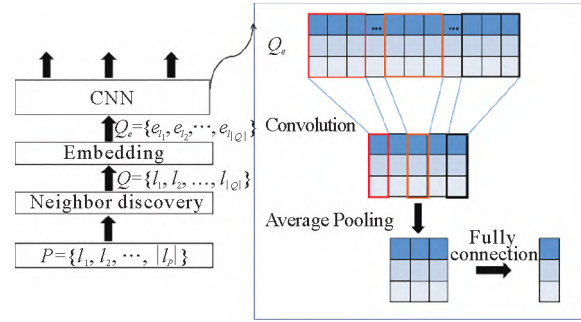


图 3 局部地理偏好模块结构图

Fig.3 Architecture of local geographical preferences module

月到 2013 年 2 月的 845 个真实用户在纽约的签到数据,共包括 12 649 个位置上的 99 205 条签到记录;Weeplaces 数据集收集了 2009 年 7 月到 2010 年 9 月的 307 个真实用户在全球的签到数据,共包括 18 288 个位置上的 127 974 条签到记录;Gowalla 数据集收集了 2010 年 1 月到 2010 年 9 月的 384 个真实用户在全球的签到数据,共包括 16 486 个位置上的 79 356 条签到记录。这 3 个数据集具有与模型相关的所有属性(用户 ID、经纬度、兴趣点 ID、签到时间)。

为了降低数据稀疏性的影响,本文对数据进行了预处理,将用户一天中所有的签到记录视为一条签到轨迹,仅保留拥有不少于 5 条签到轨迹且每条轨迹不少于 3 条签到记录的用户。对于每个用户的签到轨迹,前 80% 用作训练集,后 20% 用作测试集。

3.2 指标与参数设置

本文采用了 3 个常用的评估指标:准确率($Pre@K$)、召回率($Rec@K$),归一化贴现累计收益($NDCG@K$),定义为

$$Pre@K = \frac{1}{|U|} \sum_i \frac{|R_i \cap V_i|}{K} \quad (10)$$

$$Rec@K = \frac{1}{|U|} \sum_i \frac{|R_i \cap V_i|}{|R_i|} \quad (11)$$

$$NDCG@K = \frac{1}{|U|} \sum_i \frac{|R_i \cap G_i|}{|R_i|} \quad (12)$$

其中, K 为给每个用户推荐的 POIs 数量, R_i 为测试集中用户访问的真实位置集合, V_i 为给用户推荐的 K 个 POIs, G_i 为给用户推荐的 K 个 POIs 的等级, $|U|$ 表示用户的数量。本文取 $K = \{5, 10\}$ 来分别计算准确率、召回率和归一化贴现累计收益。

通过实验,本文将隐藏层节点数设置为 300,兴趣点和用户 ID 的嵌入维度设置为 300,时间的嵌入维度设置为 10,批量大小设置为 32,学习率设置为 0.000 1,距离约束设置为 $\Delta d = 4$ km,候选历史轨迹长度设置为 $|P| = 20$ 。另外,本文采用了 Adam 优化算法对模型中的参数进行优化。

3.3 基线

本文选择了一些经典方法与所提出模型进行了性能比较:

Markov:作为一种经典的序列预测方法,可以学习序列之间的转移概率,从而预测用户未来的访问行为,是兴趣点推荐常用的基线模型。

RNN:一种基础的处理序列数据的循环神经网络模型,由输入层、隐藏层和输出层组成,层间采用全连接的方式。

LSTM:在传统 RNN 的基础上,增加了 3 个门控机制(更新门、遗忘门、输出门),可以用来捕获长期依赖。

ST-RNN:基于 RNN 的兴趣点推荐模型,将时间信息和地理信息同时融入循环结构中。

DeepMove:该模型利用历史注意力模块捕获历史轨迹中的周期性规律,并利用循环神经网络捕获当前轨迹的时空上下文。

LSTPM:该模型考虑了长期和短期偏好,使用上下文感知非局部结构来识别历史轨迹中的时空相关性,可以捕获当前轨迹中不连续兴趣点的地理影响。

3.4 实验分析

本文所提模型与基线模型在 3 个数据集上的实验结果如图 4 所示。从图 4 可以得出以下结论:

1)在 3 个数据集上,本文所提模型在所有指标上都明显优于基线模型。而在基线模型中,LSTPM 模型在 3 个数据集上表现最好,DeepMove 模型次之。这两个模型都将用户的轨迹划分为当前轨迹和历史轨迹,将用户的短期偏好和长期偏好分开考虑。其中,LSTPM 模型的优势在于考虑了序列中的距离。因此,对于地理信息的处理在兴趣点推荐中十分重要。本文模型既利用距离关系生成了一个小的候选兴趣点集合,又对每一个兴趣点进行了评分。由于本文所提模型充分学习了地理信息对于用户选择的影响,所以在推荐准确率方面有了较大提升。

2)ST-RNN 在推荐表现上优于 LSTM、RNN,这说明除了学习序列信息,建模不同兴趣点之间的时空关系同样可以提高模型的预测能力。Markov 方法的推荐效果最差,这表明仅使用用户访问位置的转换矩阵来进行预测所包含的信息太少,导致模型无法实现较好的推荐效果。




图 4 3 个数据集上的性能比较

Fig.4 Performance comparison on three datasets

3.5 组件分析

为了验证模型中不同组件对于性能的增益,本文进一步简化了模型。

OURS-1:该模型移除了对于历史轨迹处理的组件,仅保留了处理当前轨迹的组件。

OURS-2:该模型移除了对于当前轨迹处理的组件,仅保留了处理历史轨迹的组件。

表 1 不同简化模型的性能比较

Tab.1 Performance comparison of different simplified models

数据集	Foursquare			Weeplaces			Gowalla		
模型	Pre@5	Rec@5	NDCG@5	Pre@5	Rec@5	NDCG@5	Pre@5	Rec@5	NDCG@5
OURS-1	0.397 2	0.388 4	0.292 2	0.307 8	0.313 4	0.234 2	0.284 2	0.276 1	0.232 7
OURS-2	0.437 7	0.428 1	0.310 2	0.324 7	0.348 1	0.241 1	0.293 7	0.292 1	0.245 6
OURS	0.486 6	0.472 2	0.361 8	0.390 1	0.384 4	0.286 1	0.397 4	0.388 6	0.291 2

简化模型在 3 个数据集上的实验结果如表 1 所示,可以看出:

1)模型 OURS-2 在所有指标上的表现都优于模型 OURS-1。这说明 OURS-2 的推荐准确率更高。原因在于 OURS-2 可以更好地捕捉用户签到记录中的地理信息,更好地模拟用户的长期依赖。这说明地理信息在兴趣点推荐中十分重要,也清楚地展示了本文建模个性化地理影响的优势。

2)虽然 OURS-1 比 OURS-2 略差。但是 OURS-1 的预测能力比图 4 中的很多基线要好,如:RNN、LSTM。这说明对用户短期依赖的捕获,除了序列特征,对用户个性化信息的建模也同样重要。因此,本文所提模型将 OURS-1 和 OURS-2 组合在一起,在这 3 个数据集上都取得了最好的表现。

3.6 参数分析

本文分析了兴趣点嵌入维度、候选历史轨迹长度 $|P|$ 对模型性能的影响。

图 5a 显示了在 3 个数据集上不同兴趣点嵌入维度在 Pre@5 上的结果,可以看出:嵌入维度在 $[300, 500]$ 范

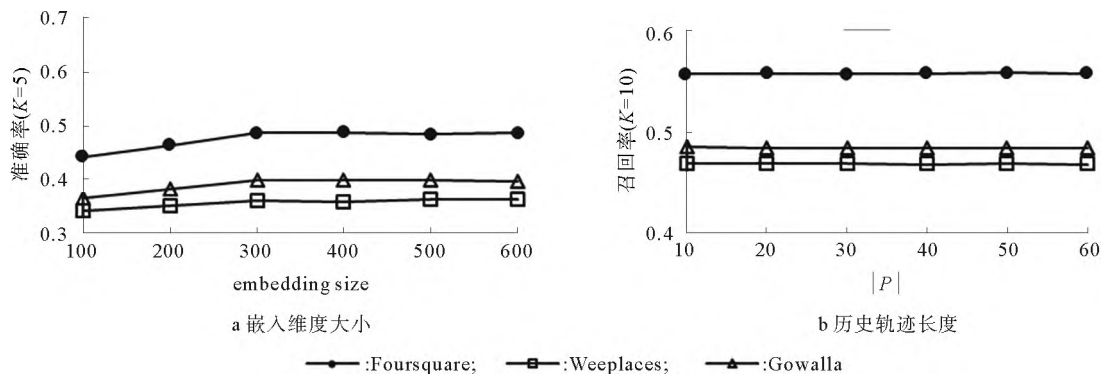


图 5 不同参数的性能比较

Fig.5 Performance comparison of different parameters

围内,模型性能基本是稳定。这是因为维度过低时,会丢失很多特征;维度过高时,又会产生无关的噪声信息。最终,本文将 300 作为兴趣点的嵌入维度,一方面可以减少参数量,另一方面可以提高运算效率。

图 5b 显示了在 3 个数据集上不同候选历史轨迹长度 $|P|$ 在 Rec@10 上的结果,可以看出,候选历史轨迹长度 $|P|$ 对于模型的预测性能几乎没有影响。这说明绝大多数用户不存在 2.2.1 节中所提到的历史轨迹不存在的情况。

4 结论

本文提出了一种融合时间和地理信息的兴趣点推荐模型。首先,针对时间对用户访问行为的不同影响,本文将用户轨迹划分为工作日轨迹和节假日轨迹,并在此基础上进行了当前轨迹和历史轨迹的划分。其次,模型分别利用时空关系模块和地理关系模块学习不同轨迹中的特征。具体而言,时空关系模块利用长短期记忆网络学习当前轨迹中的时空特征;地理关系模块一方面通过卷积神经网络学习邻居兴趣点的特征;另一方面根据用户之间的相似度,生成用户对兴趣点的评分矩阵。实验证明,本文所提模型在兴趣点推荐性能方面优于现有的其他模型。目前的兴趣点推荐研究都是针对单个用户,未来可以考虑根据社交关系以用户组的形式进行兴趣点推荐。

参考文献:

- [1] MA Y, GAN M. Exploring multiple spatio-temporal information for point-of-interest recommendation[J]. *Soft Computing*, 2020, 24: 18733-18747.
- [2] 杨晓蕾, 李胜, 何熊熊, 等. 基于张量分解的多维信息融合兴趣点推荐算法[J]. *小型微型计算机系统*, 2020, 41(5): 902-907.
YANG X L, LI S, HE X X, et al. Multi-dimensional information fused point-of-interest recommendation based on tensor decomposition[J]. *Journal of Chinese Computer Systems*, 2020, 41(5): 902-907.
- [3] 董婵娟, 李胜, 何熊熊, 等. 融合地理信息、种类信息与隐式社交关系的兴趣点推荐算法[J]. *模式识别与人工智能*, 2021, 34(2): 106-116.
DONG C J, LI S, HE X X, et al. Point of interest recommendation algorithm integrating geo-category information and implicit social relationship[J]. *Pattern Recognition and Artificial Intelligence*, 2021, 34(2): 106-116.
- [4] CHEN J W, LI J B, AHMED M, et al. Next location prediction with a graph convolutional network based on a seq2seq framework[J]. *KSI Transactions on Internet and Information Systems*, 2020, 14(5): 1909-1928.
- [5] ZHANG J Y, LIU X, ZHOU X F, et al. Leveraging graph neural networks for point-of-interest recommendations[J]. *Neurocomputing*, 2021, 462: 1-13.
- [6] 邵长城, 陈平华. 融合社交网络和图像内容的兴趣点推荐[J]. *计算机应用*, 2019, 35(5): 1261-1268.
SHAO C C, CHEN P H. Point-of-interest recommendation integrating social networks and visual contents[J]. *Journal of Computer Applications*, 2019, 39(5): 1261-1268.
- [7] HE J, LI X, LIAO L J, et al. Inferring a personalized next point-of-interest recommendation model with latent behavior patterns[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*. California, USA, 2016: 137-143.
- [8] 陶永才, 曹朝阳, 石磊, 等. 一种结合时间因子聚类的群组兴趣点推荐模型[J]. *小型微型计算机系统*, 2020, 41(2): 356-360.
TAO Y C, CAO Z Y, SHI L, et al. Group poi recommendation model based on time factor clustering[J]. *Journal of Chinese Computer Systems*, 2020, 41(2): 356-360.
- [9] ZHAO P, LUO A, LIU Y, et al. Where to go next: a spatio-temporal gated network for next poi recommendation[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2020, 34(5): 2512-2524.
- [10] FENG J, LI Y, ZHANG C, et al. Deepmove: predicting human mobility with attentional recurrent networks[C]//*Proceedings of the 2018 World Wide Web Conference*. Lyon, France, 2018: 1459-1468.
- [11] CHENG C, YANG H, LYU M R, et al. Where you like to go next: successive point-of-interest recommendation[C]//*Twenty-Third International Joint Conference on Artificial Intelligence*. Beijing, China, 2013: 2605-2611.
- [12] SUN K, QIAN T, CHEN T, et al. Where to go next: modeling long-and short-term user preferences for point-of-interest recommendation[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*. New York, USA, 2020: 214-221.
- [13] LIAN D, ZHAO C, XIE X, et al. GeoMF: joint geographical modeling and matrix factorization for point-of-interest recommendation[C]//*Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York, USA, 2014: 831-840.

- (责任编辑 李 进)

- [14] YU X, CHU X, JIANG Y, JIANG F, et al. SVMs classification based two-side cross domain collaborative filtering by inferring intrinsic user and item features[J]. Knowledge-Based Systems, 2018, 141: 80-91.
- [15] YU X, JIANG F, DU J, et al. A cross-domain collaborative filtering algorithm with expanding user and item features via the latent factor space of auxiliary domains[J]. Pattern Recognition, 2019, 94(1): 96-109.
- [16] YU X, PENG Q, XU L, et al. A selective ensemble learning based two-sided cross-domain collaborative filtering algorithm[J]. Information Processing & Management, 2021, 58(6): 102691.
- [17] YE M, YIN P, LEE W C, et al. Exploiting geographical influence for collaborative point-of-interest recommendation[C]//Proceedings of the 34th International ACM SIGIR Conference on Research and Development in Information Retrieval, Beijing, China, 2011: 325-334.
- [18] 夏英, 张金凤. 融合社交关系和局部地理因素的兴趣点推荐[J]. 计算机工程与应用, 2021, 57(15): 133-139.
XIA Y, ZHANG J F. Poi recommendation fusing social relations and local geographic factors[J]. Computer Engineering and Applications, 2021, 57(15): 133-139.
- [19] ZHONG C Y, ZHU J H, XI H R. PS-LSTM: popularity analysis and social network for point-of-interest recommendation in previously unvisited locations[C]//Proceedings of 2021 2nd International Conference on Computing, Networks and Internet of Things, Beijing, China, 2021: 1-6.
- [20] LIU Y, PEI A, WANG F, et al. An attention-based category-aware gru model for the next poi recommendation[J]. International Journal of Intelligent Systems, 2021, 36(7): 3174-3189.
- [21] LIU Q, WU S, WANG L, et al. Predicting the next location: a recurrent model with spatial and temporal contexts[C]//Proceedings of the AAAI Conference on Artificial Intelligence, Arizona, USA, 2016: 194-200.
- [22] XING S, LIU F, WANG Q, et al. Content-aware point-of-interest recommendation based on convolutional neural network[J]. Applied Intelligence, 2019, 49(3): 858-871.
- [23] SAFARI S, JALALI M. RecPOID: poi recommendation with friendship aware and deep cnn[J]. Future Internet, 2021, 13(3): 1-14.

(责任编辑 耿金花)